多模态人工智能系统
全国重点实验室
State Key Laboratory of
Multimodal Artificial Intelligence Systems
MAIS

计算机视觉

图像局部特征提取

董秋雷

中国科学院自动化研究所

多模态人工智能系统全国重点实验室



目 录

一、局部特征匹配
（1）SIFT特征点
（2）ORB特征点
二、特征描述子学习
三、ICP算法
四、鲁棒匹配——RANSAC

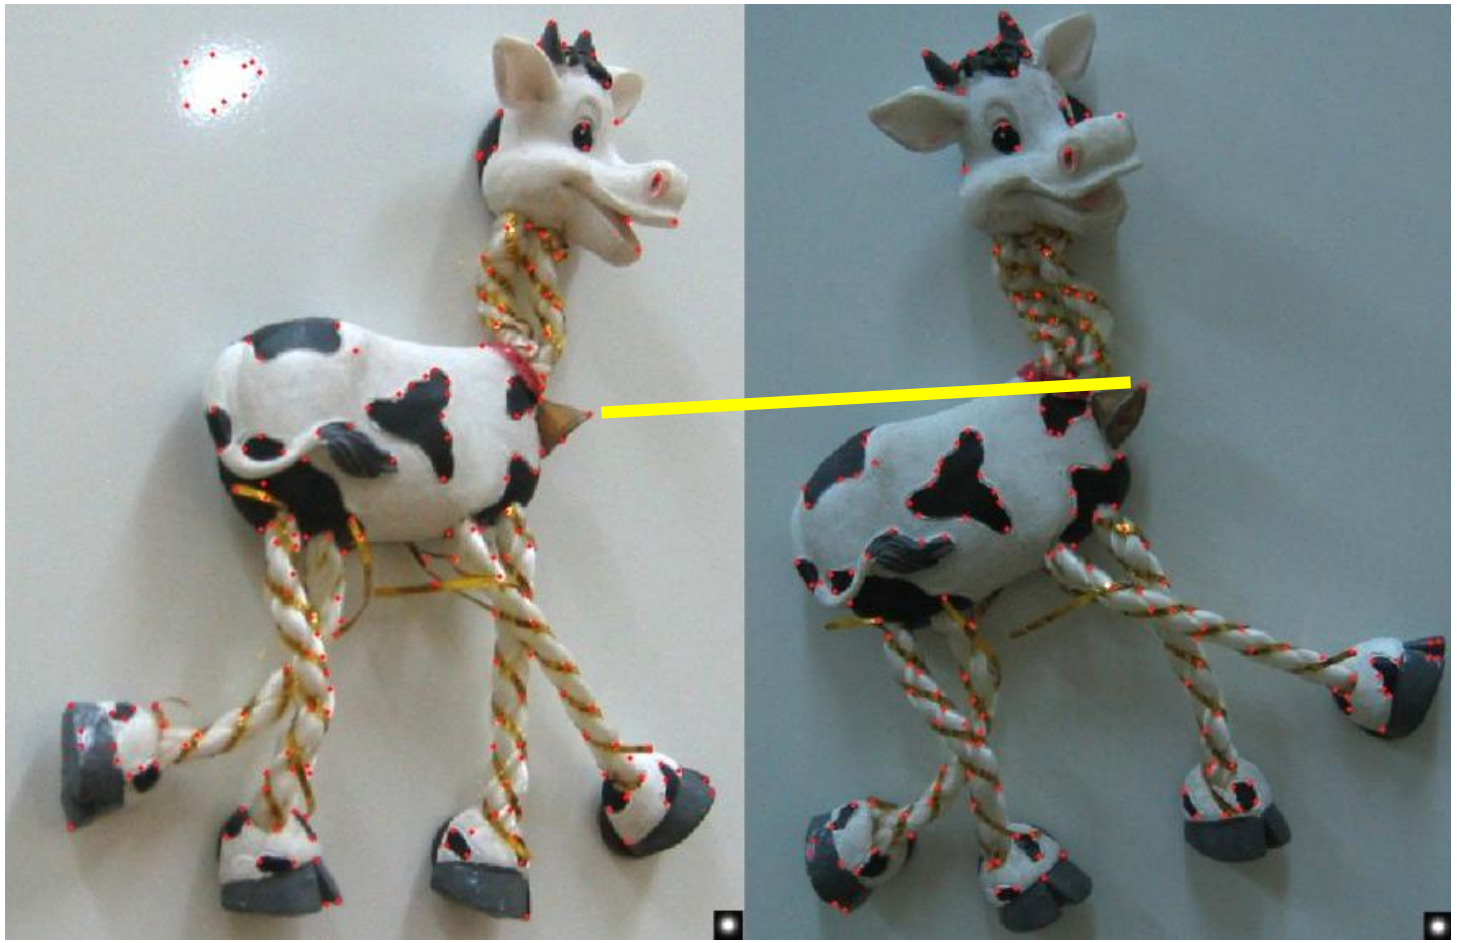


数字图像



数字图像

特征提取



数字图像

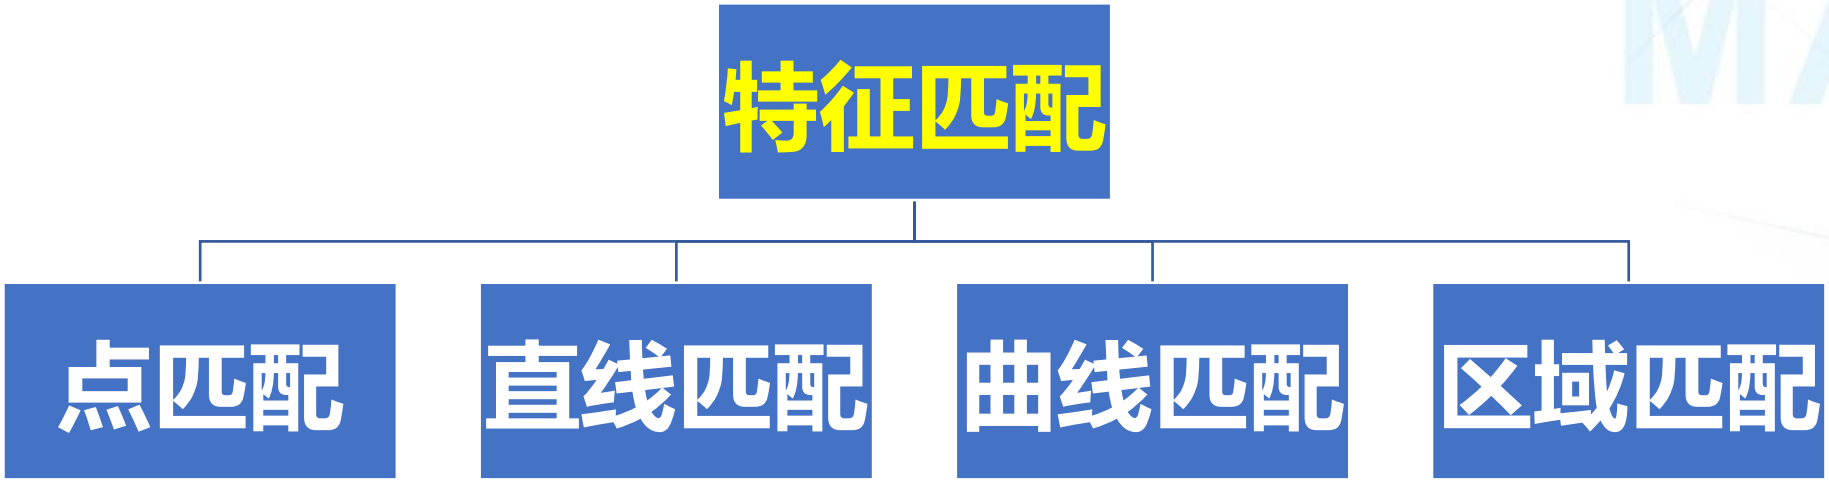
特征提取

特征描述

特征匹配

匹配：确定不同图像中对应空间同一物体的投影的过程

匹配是基于多幅图像视觉问题的的基本步骤



点匹配的基本原则：

- 利用图像点周围的信息来描述点，如灰度、颜色、梯度等，然后进行相似性度量。

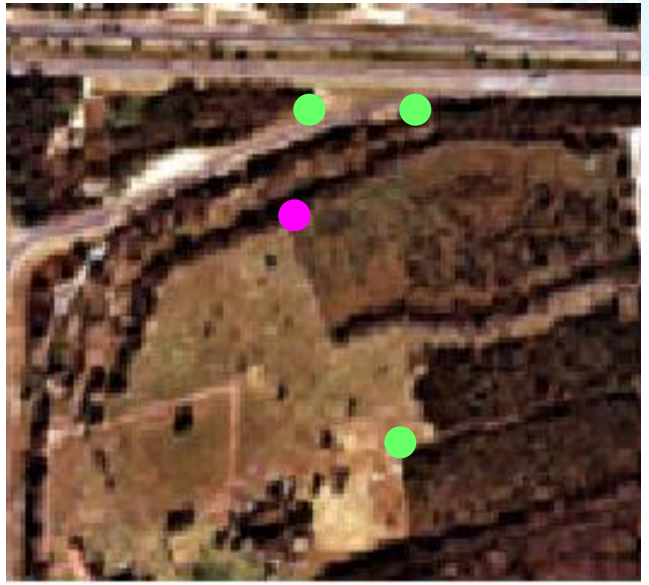
Cross-correlation基本原理

特征点匹配

利用相关函数，评价两幅图像特征点邻域的灰度相似性以确定对应点。

示意图





特征点描述



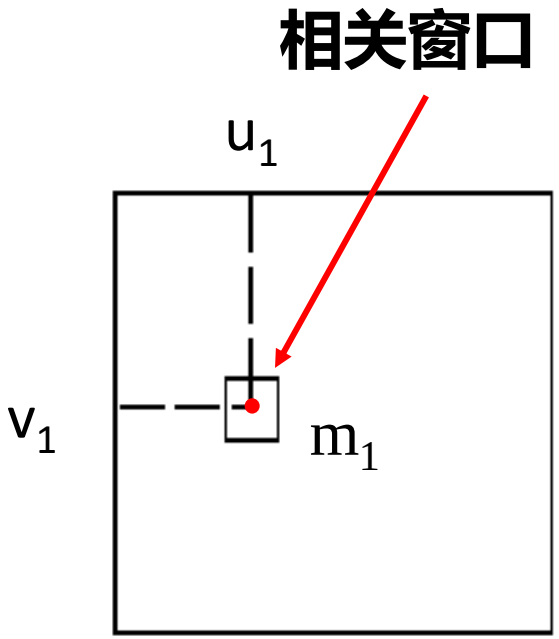
相关函数



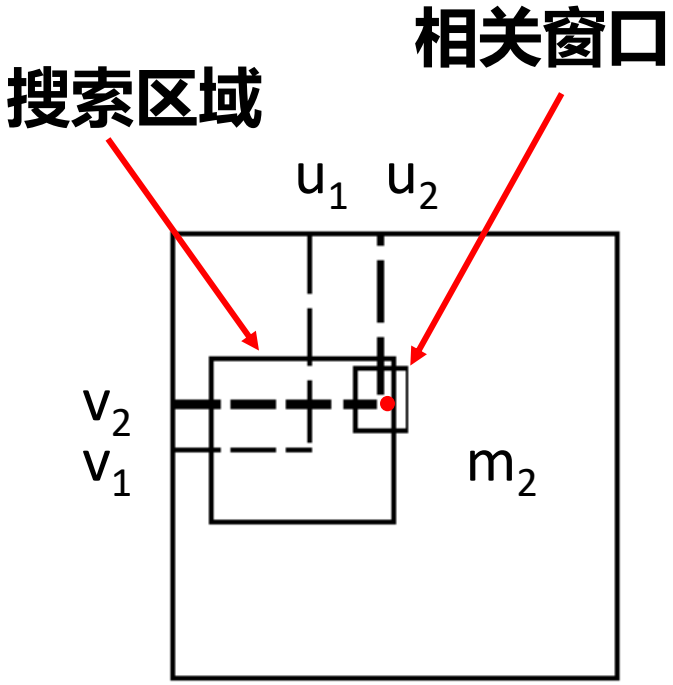
对应点

相似程度

相关窗口和搜索区域



图像1



图像2

相关函数

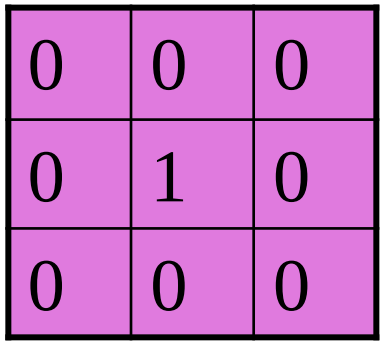
$$Score(m_1, m_2) = \frac{\sum_{i=-n}^{n}\sum_{j=-m}^{m}[I_1(u_1+i, v_1+j) - \overline{I_1}\,(u_1, v_1)] \times [I_2(u_2+i, v_2+j) - \overline{I_2}\,(u_2, v_2)]}{(2n+1)(2m+1)\sqrt{\sigma^2(I_1) \times \sigma^2(I_2)}}$$

$$\overline{I_k}\,(u, v) = \frac{\sum_{i=-n}^{n}\sum_{j=-m}^{m} I_k(u+i, v+j)}{(2n+1)(2m+1)}$$ **均值**

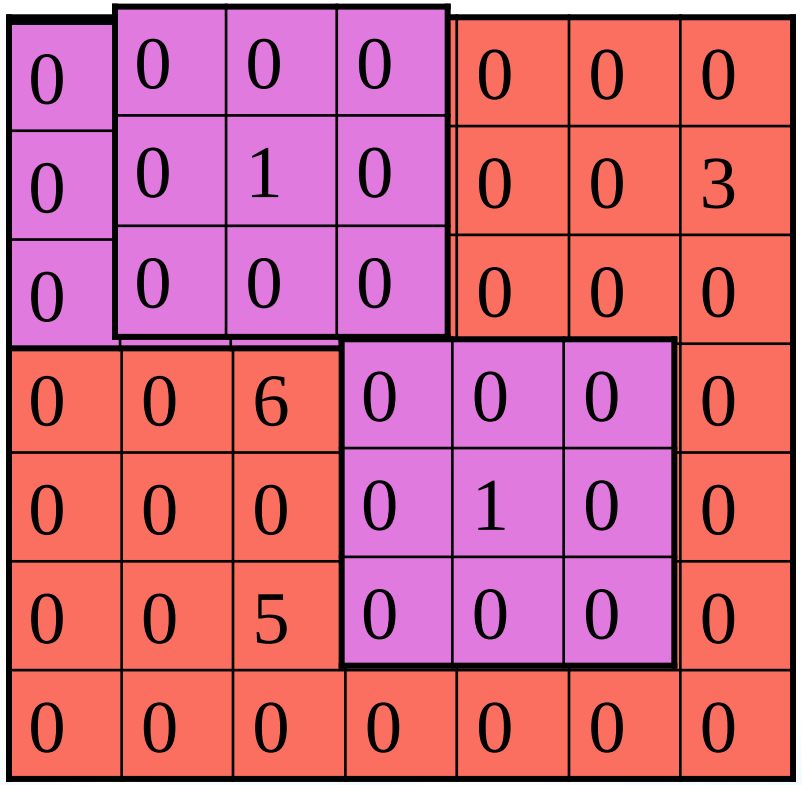
$$\sigma(I_k) = \sqrt{\frac{\sum_{i=-n}^{n}\sum_{j=-m}^{m}[I_k(u+i, v+j) - \overline{I_k}\,(u, v)]^2}{(2n+1)(2m+1)}}$$ **标准差**

搜索过程

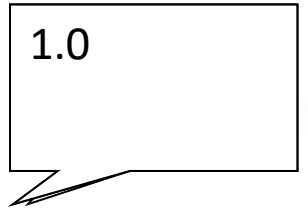
利用计算机对数字影像进行数值计算完成匹配



相关窗口



搜索区

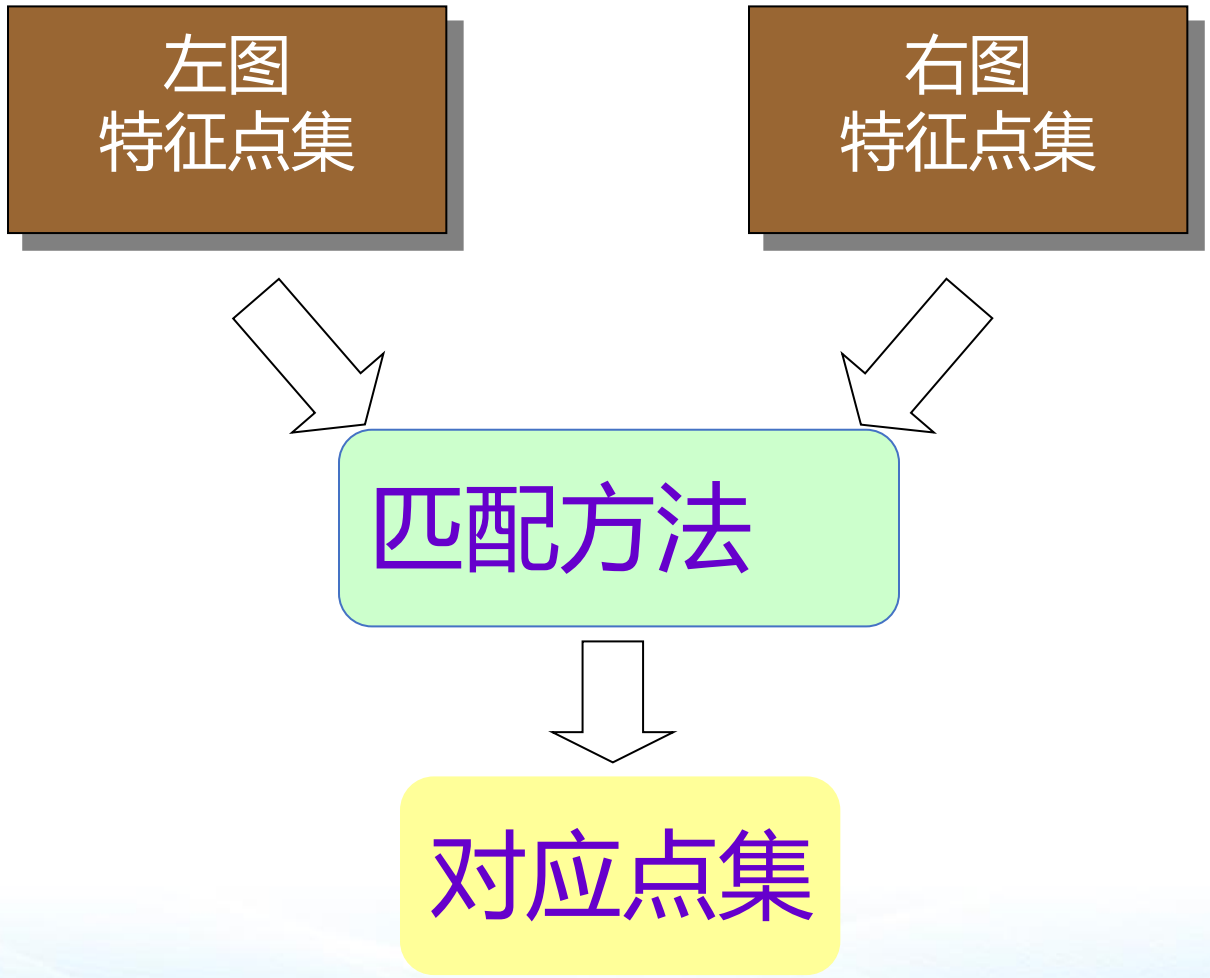


相似度

匹配

左图每个特征点对应右图的一个候选匹配集

右图每个特征点对应左图的一个候选匹配集


左图
特征点集
右图
特征点集
匹配方法
对应点集

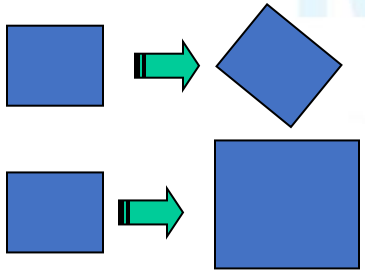
Cross-correlation特点

- 基于图像灰度
- 如何确定窗口大小和形状是最大的问题
- 没有旋转不变性
- 对光照变化敏感
- 计算代价大

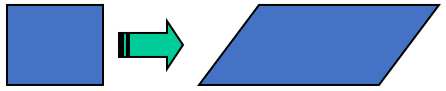
SIFT特征

图像变化的类型

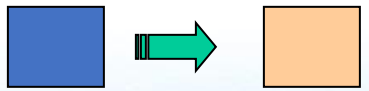
- 几何变化
  - 旋转
  - 相似(旋转 + 各向相同的尺度缩放)



  - 仿射 (非各向相同的尺度缩放)
    适用于: 物体局部为平面



- 灰度变化
  - 仿射灰度变化 ($I \rightarrow a\,I + b$)



SIFT--(Scale Invariant Feature Transform)

- SIFT特征提取算法（Lowe1999, 2004）：DoG 特征检测 + SIFT 描述子
- 迄今使用最为广泛的点特征提取方法



David Lowe

关注

Computer Science Dept., University of British Columbia
在 cs.ubc.ca 的电子邮件经过验证 - 首页
Computer Vision Object Recognition

标题	引用次数	年份
Distinctive image features from scale-invariant keypoints DG Lowe International journal of computer vision 60 (2), 91-110	55841	2004
Object recognition from local scale-invariant features DG Lowe International Conference on Computer Vision, 1999, 1150-1157	18697	1999
Fast Approximate Nearest Neighbors with Automatic Algorithm Configuration. M Muja, DG Lowe VISAPP (1) 2, 331-340	2981	2009
Automatic panoramic image stitching using invariant features M Brown, DG Lowe International Journal of Computer Vision 74 (1), 59-73	2545	2007

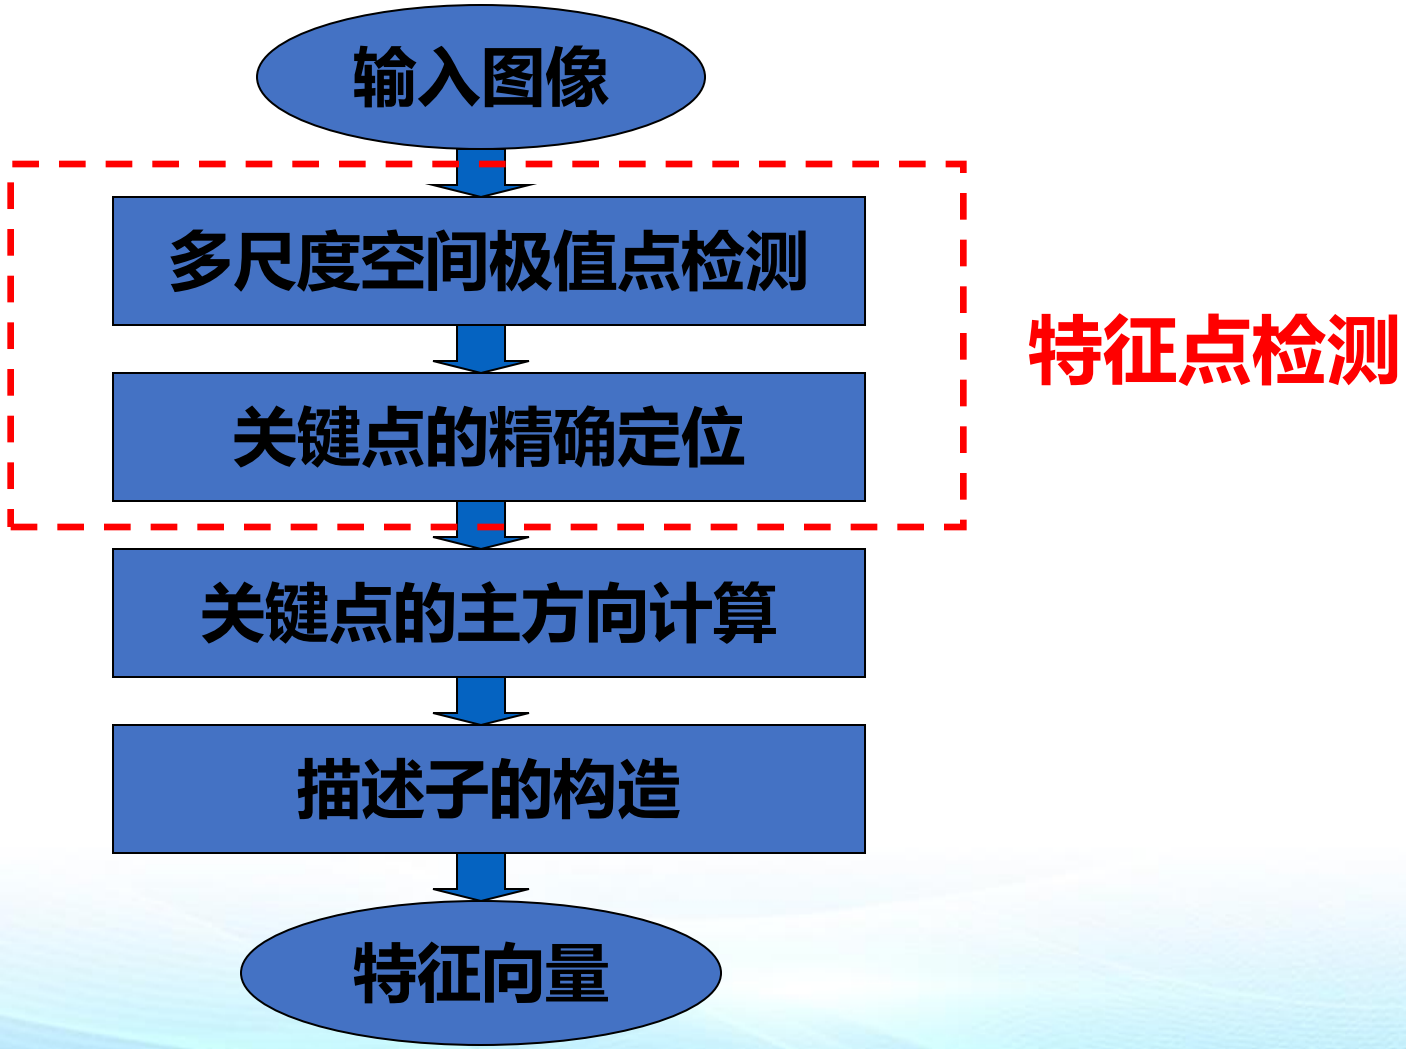
知乎 @AI科技大本营

- David G. Lowe, Distinctive Image Features from Scale-Invariant Keypoints, International Journal of Computer Vision, Vol. 60, Page 91-110, 2004.

SIFT特征的性质

- 不变性
  - 对图像的旋转和尺度变化具有不变性
  - 对三维视角变化和光照变化具有很强的适应性
  - 局部特征，在遮挡和场景杂乱时仍保持不变性
- 辨别力强
  - 特征之间相互区分的能力强，有利于匹配
- 数量较多
  - 一般500×500的图像能提取出约2000个特征点
- 扩展性强

SIFT特征提取算法流程



尺度空间的定义

- 目的：检测在尺度变化时仍然稳定的特征
- 定义图像$I(x,y)$的尺度空间：

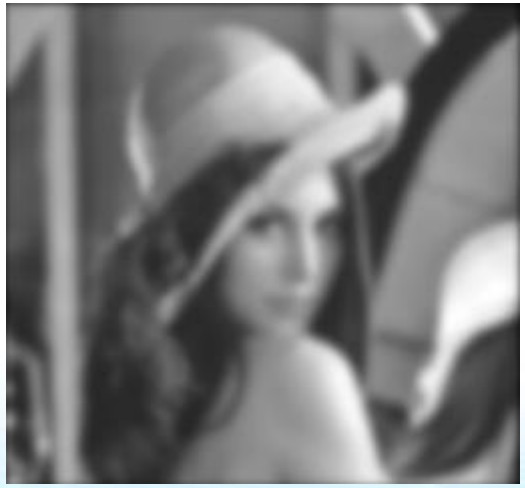
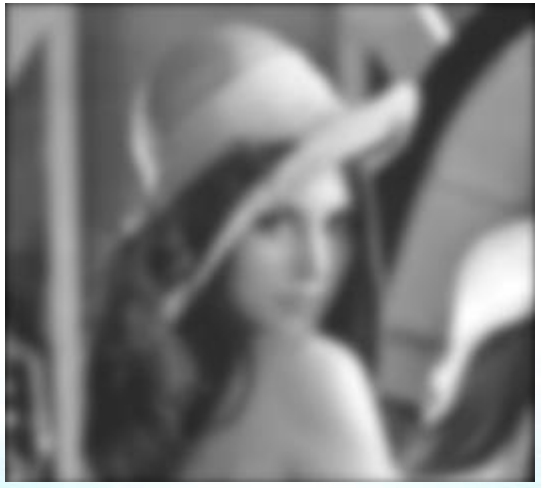
$$L(x,y,\sigma) = G(x,y,\sigma) * I(x,y)$$

其中，$G(x,y,\sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}$

- 尺度参数σ，当σ连续变化，$G(x,y,\sigma)$构成图像的尺度空间

图像尺度空间




高斯差分尺度空间

- 为了在尺度空间中检测稳定的关键点，构造高斯差分（DoG: Difference of Gaussian）尺度空间：

$$D(x,y,\sigma) = \big(G(x,y,k\sigma) - G(x,y,\sigma)\big) * I(x,y)$$
$$= L(x,y,k\sigma) - L(x,y,\sigma)$$

几个理由：

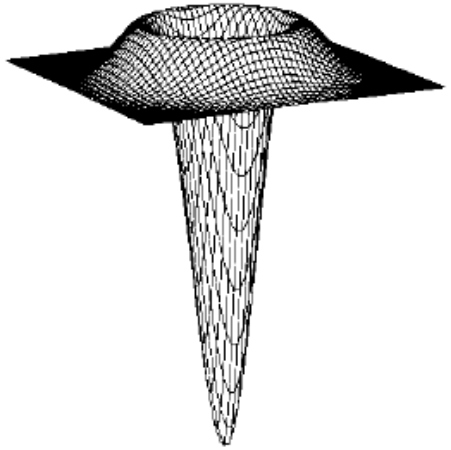
（1） 计算效率高：高斯卷积，减法

（2） 高斯差分是对尺度归一化LoG的一个很好的近似, 而尺度归一化的LoG空间具有真正的尺度不变性 (Lindegerg 1994)

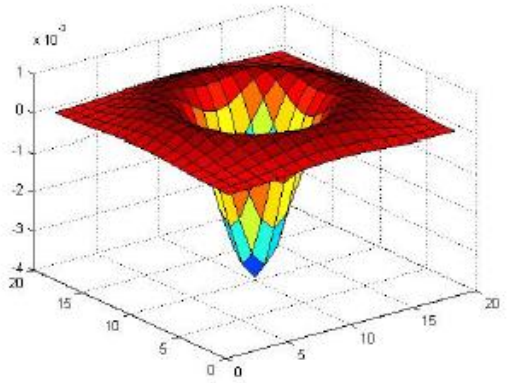
（3） 实验比较表明，从尺度归一化LoG空间中提取的图像特征的尺度稳定性最好，优于梯度、Hessian或Harris角点函数。

高斯差分尺度空间

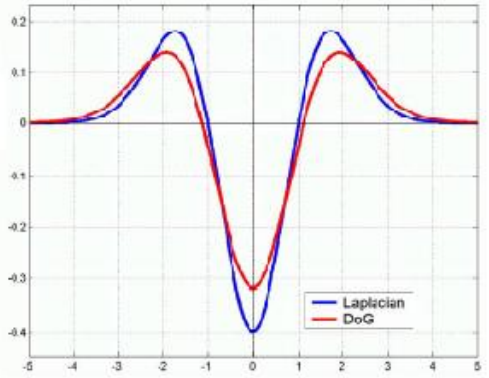
- LoG VS DoG



LoG



DoG

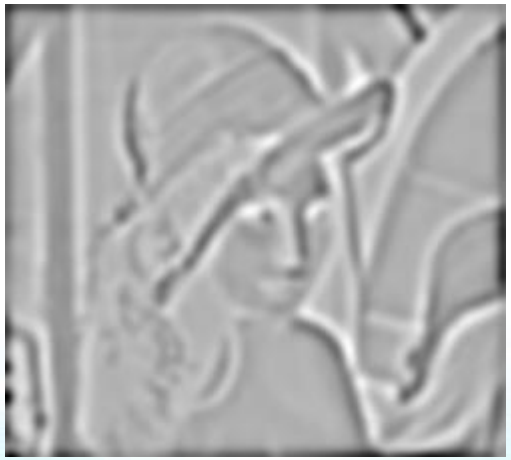
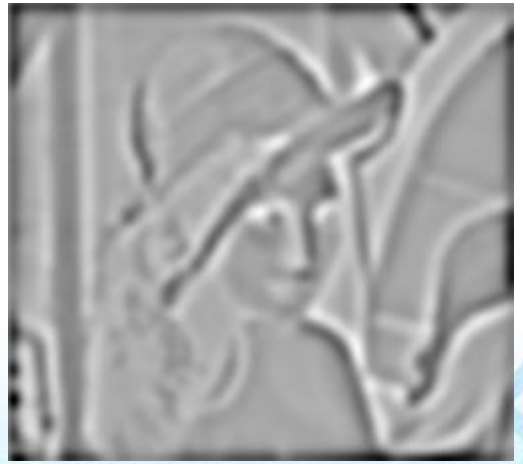


(b)

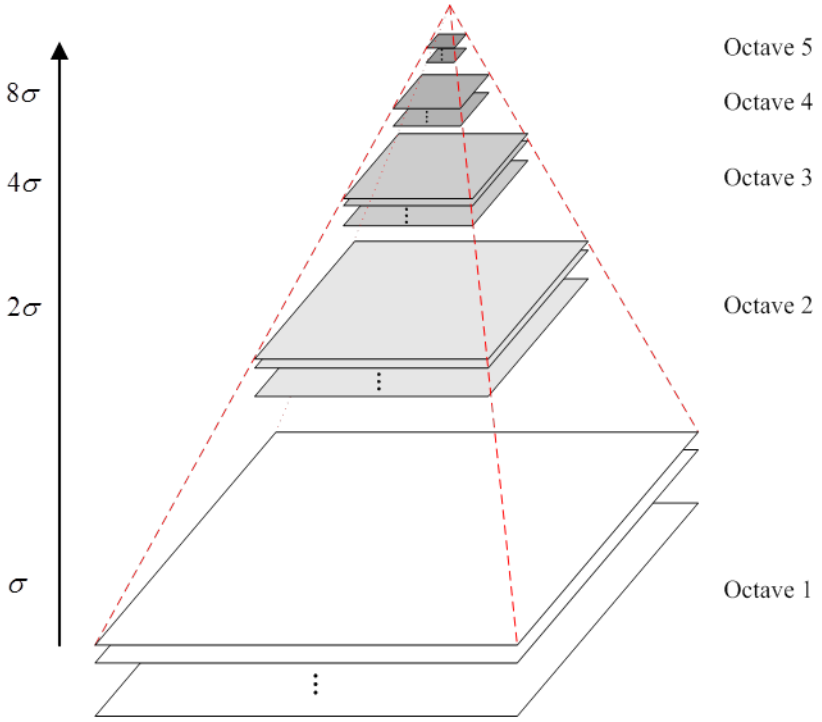
高斯差分尺度空间

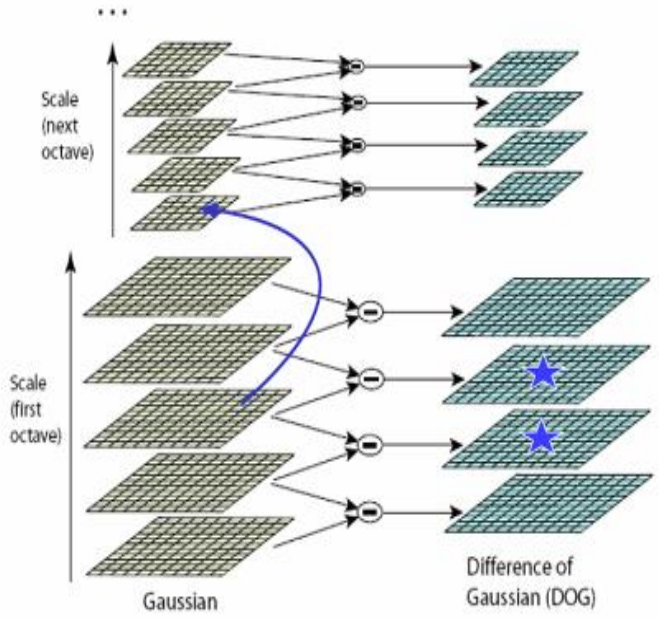




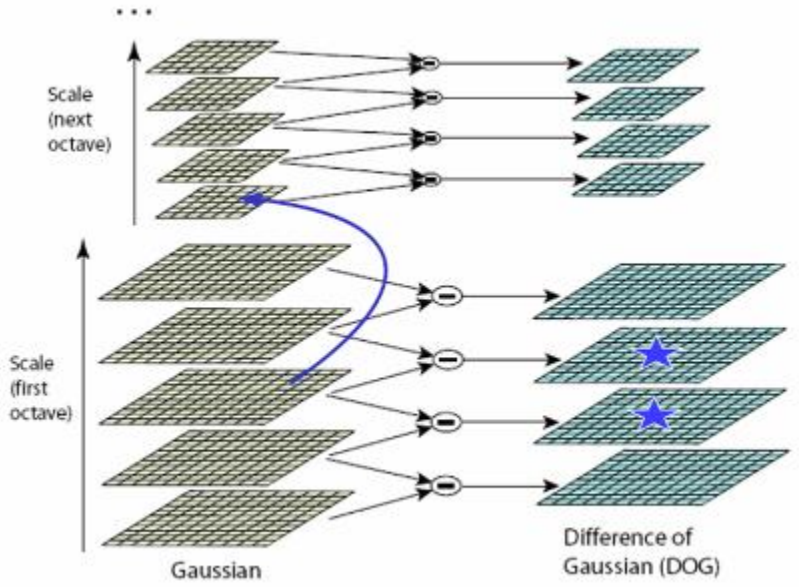
高斯金字塔


8σ
4σ
2σ
σ
Octave 5
Octave 4
Octave 3
Octave 2
Octave 1


Scale (next octave)
Scale (first octave)
Gaussian
Difference of Gaussian (DOG)

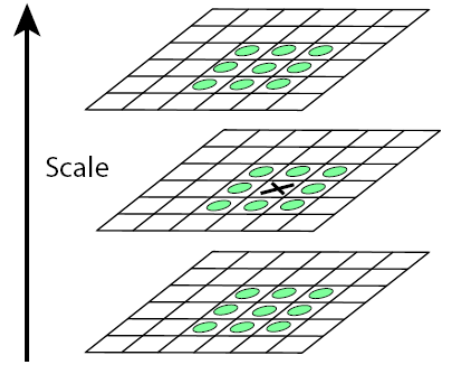
DoG尺度空间极值点检测

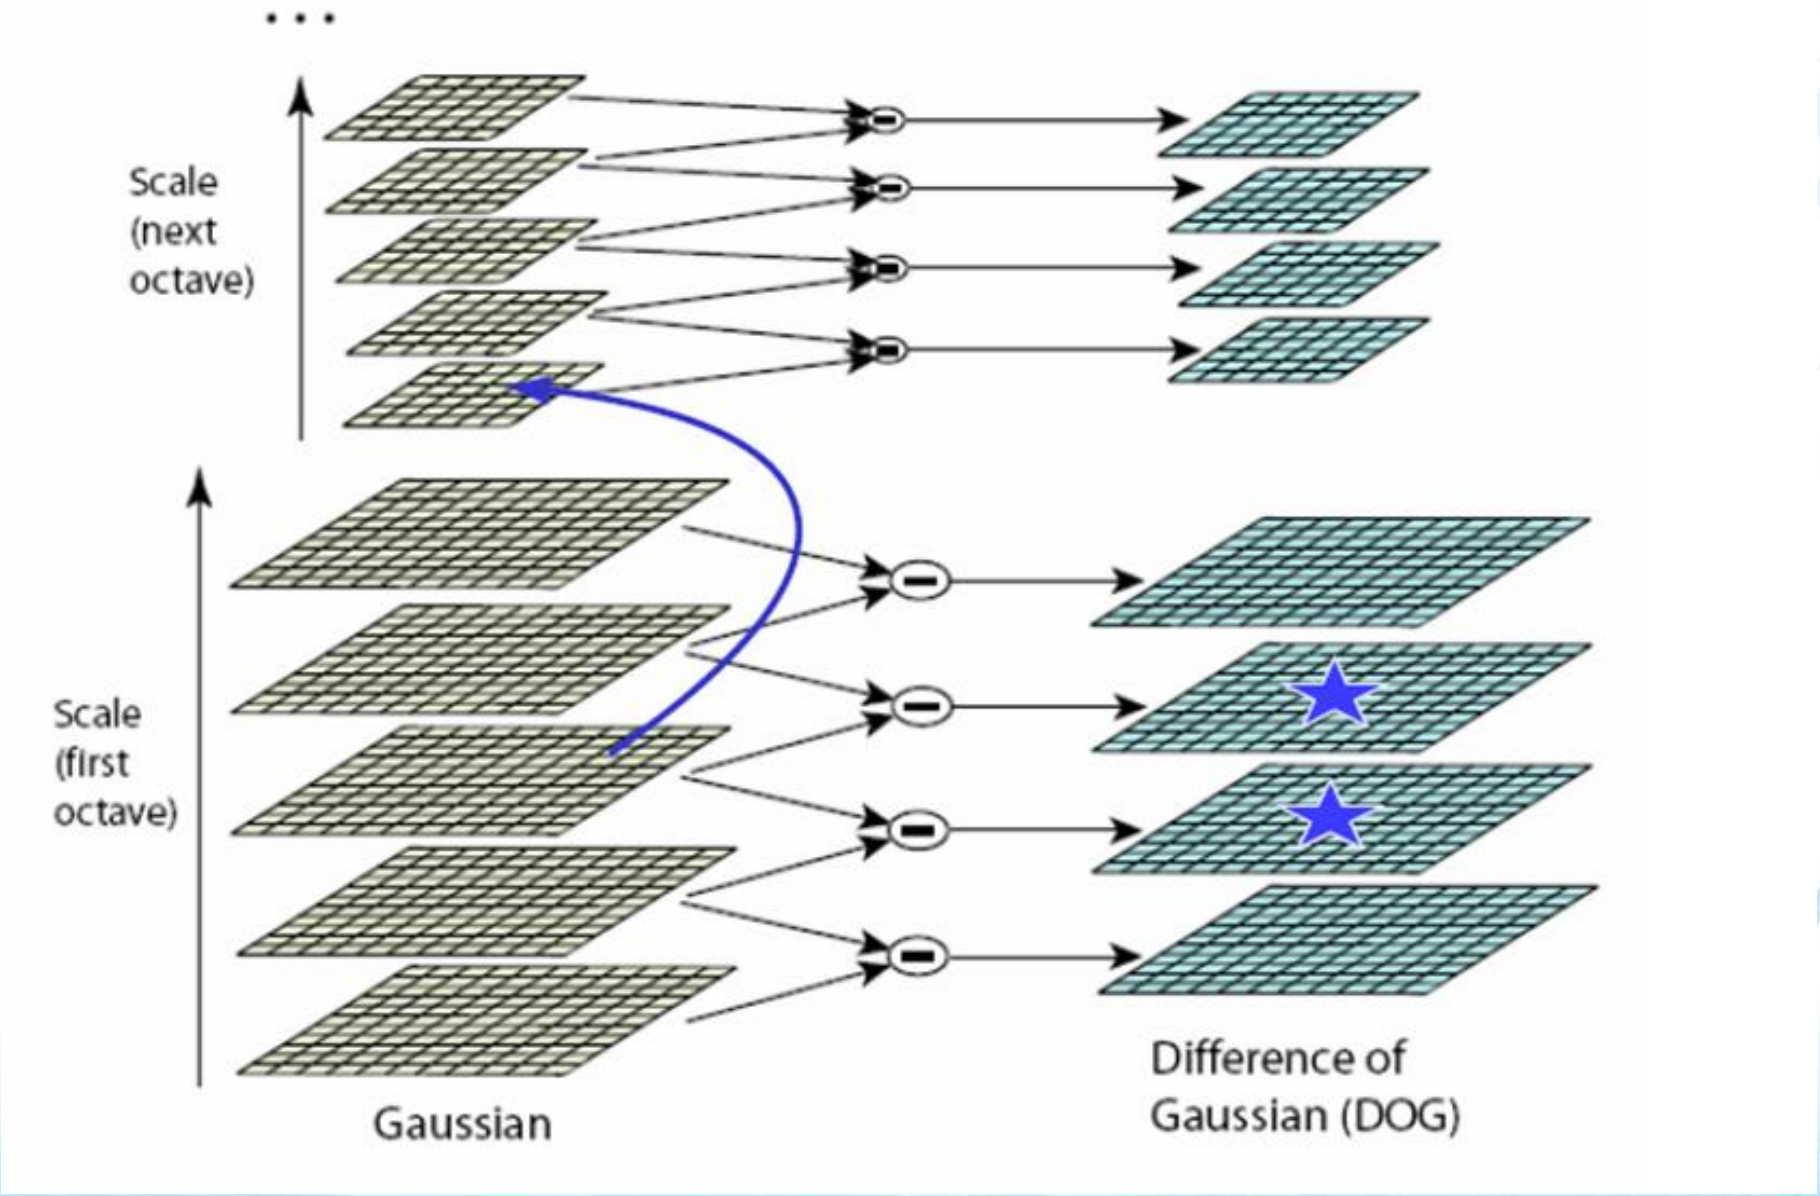
建立的三维尺度空间形式



极值点检测：

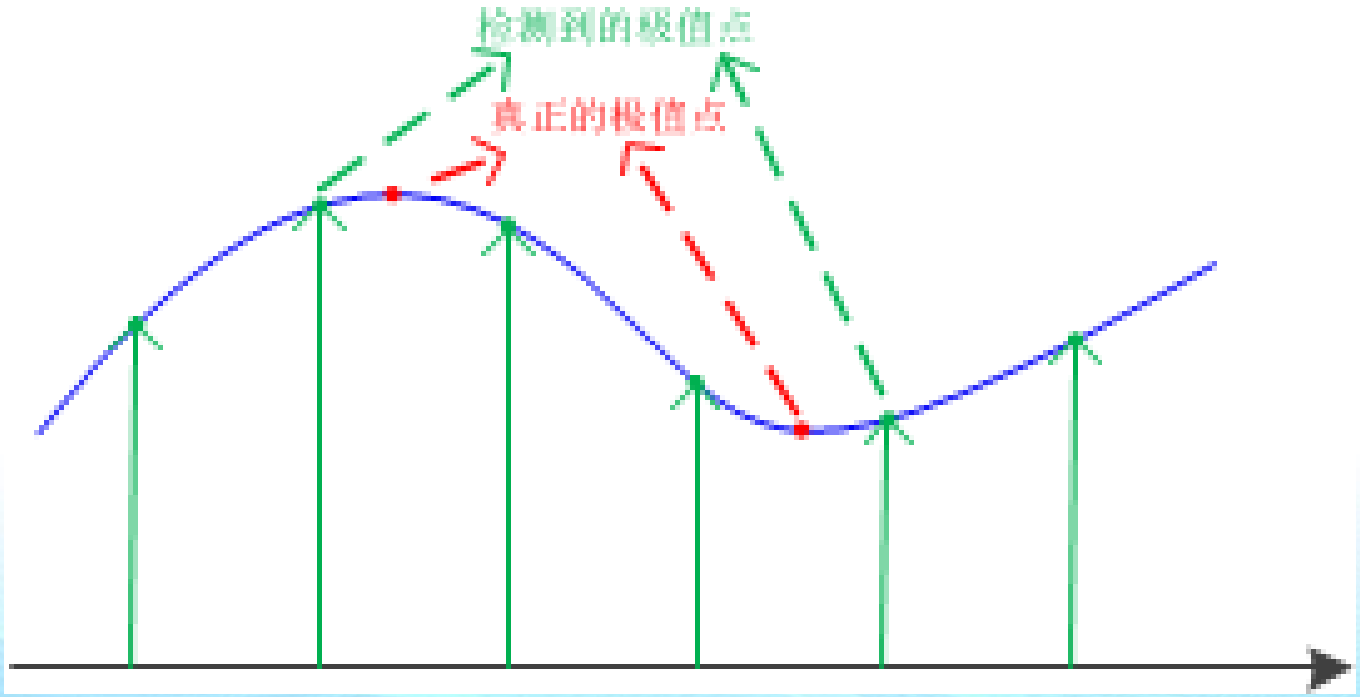
在三维尺度空间$D(x, y, \sigma)$中，搜索每个点的26邻域，若该点为局部极值点，则保存为候选关键点。




Scale
(next
octave)
Scale
(first
octave)
Gaussian
Difference of
Gaussian (DOG)

关键点的精确定位

- 动机：在离散采样中搜索到的极值点不一定是真实空间的极值点。
- 基本原理：对尺度空间DoG函数进行曲线拟合，计算其极值点，从而实现关键点的精确定位。



关键点的精确定位

- 三元二次函数拟合 $D(\mathrm{x}) = D + \frac{\partial D^T}{\partial \mathrm{x}}\mathrm{x} + \frac{1}{2}\mathrm{x}^T\frac{\partial^2 D}{\partial \mathrm{x}^2}\mathrm{x}$

计算精细偏移量

$$\hat{\mathrm{x}} = -\frac{\partial^2 D^{-1}}{\partial \mathrm{x}^2}\frac{\partial D}{\partial \mathrm{x}}$$

若$\hat{\mathrm{x}} = (\hat{x}, \hat{y}, \hat{\sigma})^T$中的三个变量任意一个偏移量大于0.5（精确极值点更接近于另一个邻点）

改变关键点的初始位置x，重复计算精细偏移量

去除不稳定的关键点

- **去除对比度低的点** $D(\hat{\mathrm{x}}) = D + \frac{1}{2}\frac{\partial D^T}{\partial \mathrm{x}}\hat{\mathrm{x}}$

设定阈值 $|D(\hat{\mathrm{x}})| < 0.03$

- **去除边缘上的点**

利用Hessian矩阵H判断关键点是否位于边缘

$$H = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{bmatrix}$$

H的两个特征值对应两个方向上的主曲率大小。在边缘位置，两个特征值的比值

设两个特征值之间的比值为r： $\lambda_1 = r\lambda_2$

$$\frac{\mathrm{Tr}^2(H)}{\mathrm{Det}(H)} = \frac{(\lambda_1+\lambda_2)^2}{\lambda_1\lambda_2} = \frac{(r\lambda_2+\lambda_2)^2}{r\lambda_2\lambda_2} = \frac{(r+1)^2}{r} > \frac{(10+1)^2}{10}$$

通过计算H的迹和行列式避免直接求特征值，减少了计算量.

30

例子



原始图像
大小233*189像素



多尺度DoG空间中的极值点
832个

例子

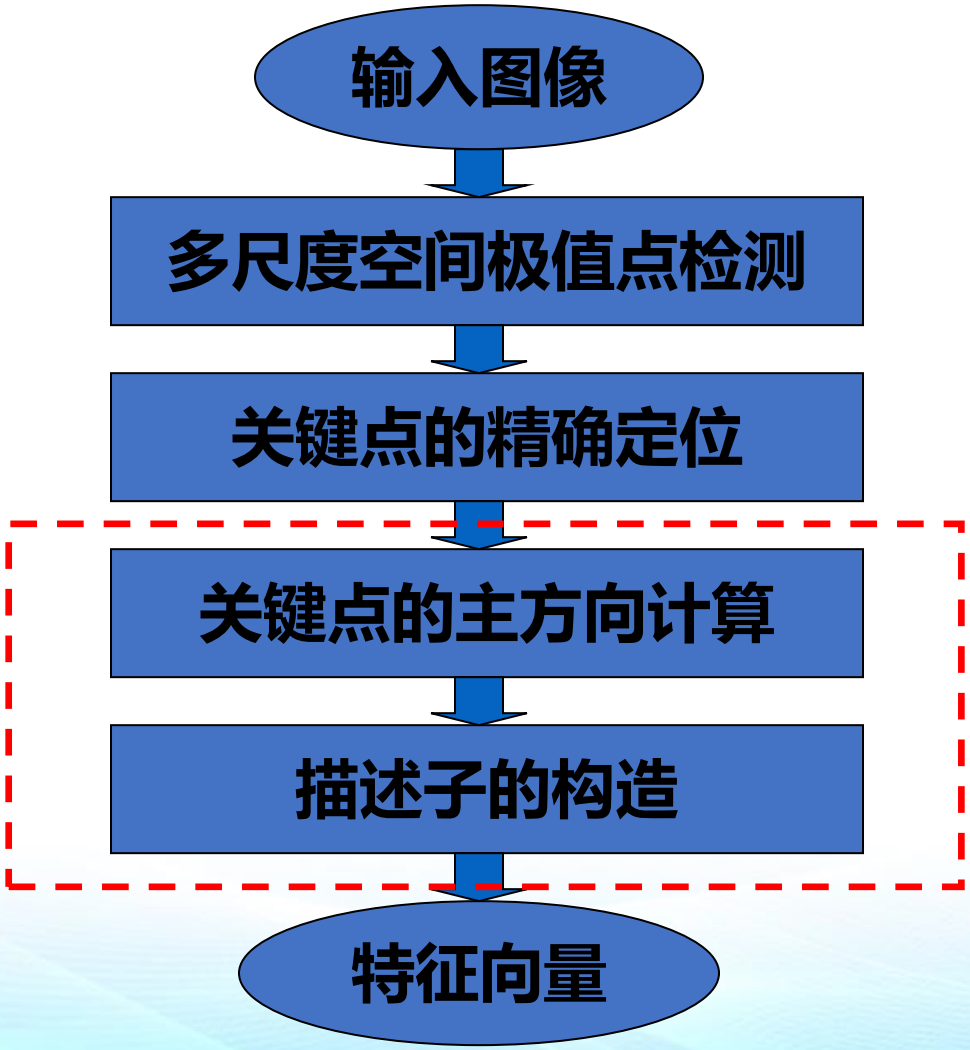


对比度阈值处理
832 → 729

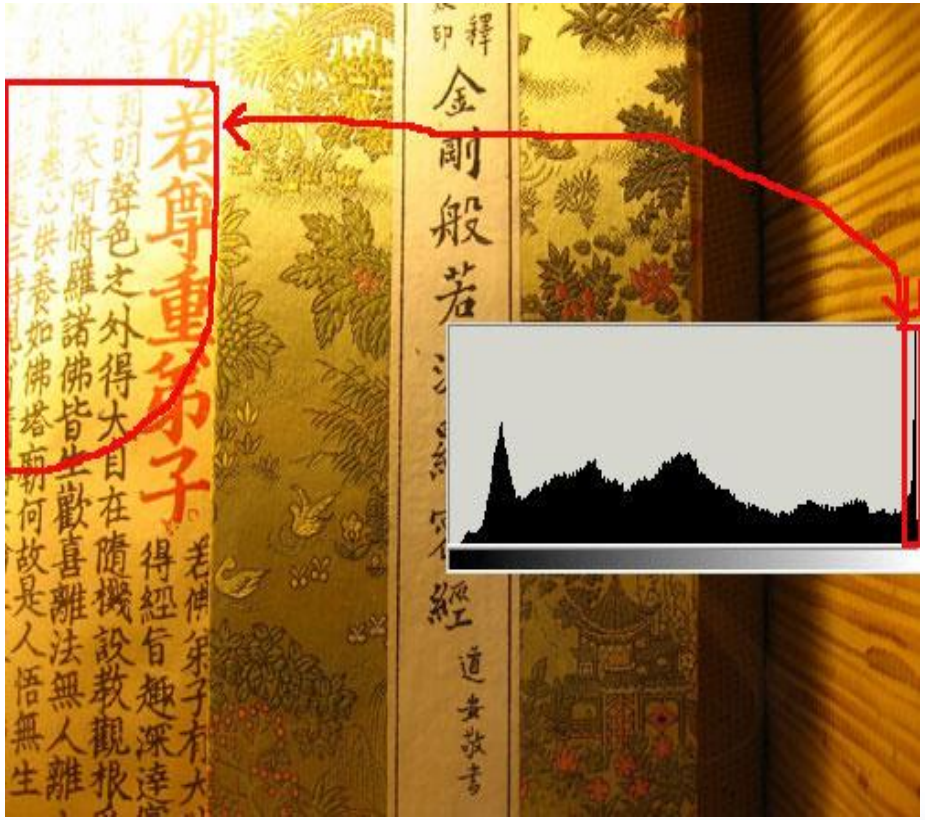


去除边缘上的点
729 → 536

SIFT特征匹配算法



直方图(Histogram)



直方图表示的是图像中每[illegible]统计[illegible]示频数。

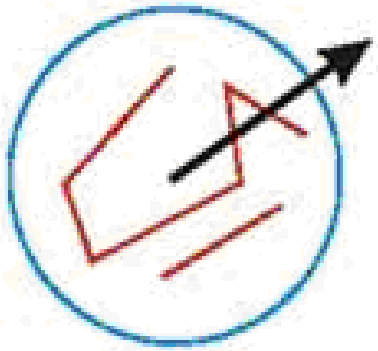
原始定义

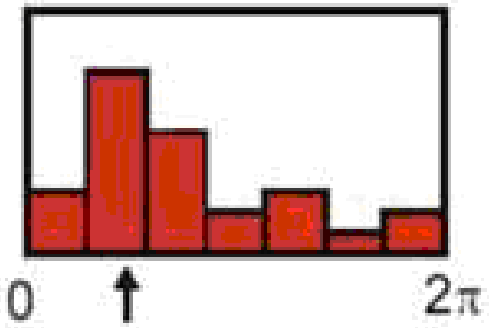
推广

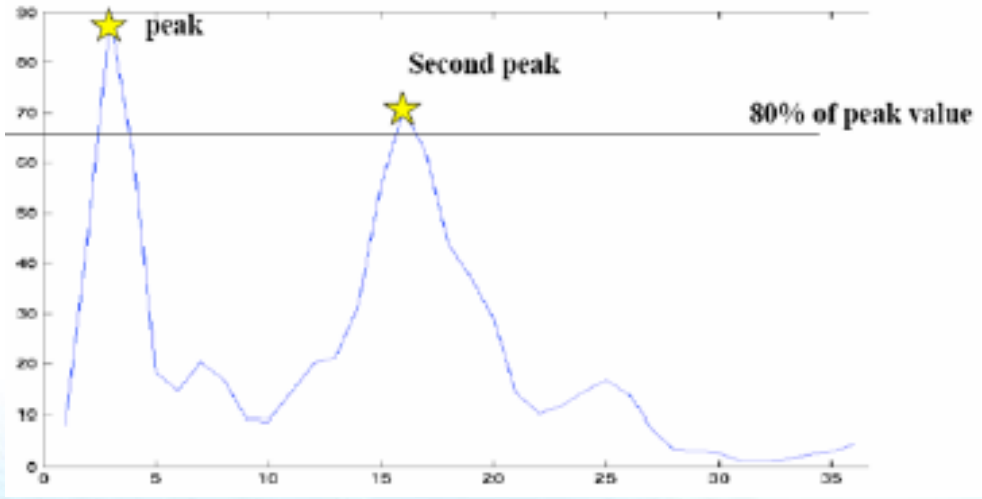
一般意义

主方向计算









分圆周为角度区间

统计梯度幅值和

抛物线插值

精确定位主方向

特征点主方向

$$\Omega_r = \{X_j : ||X_j - X|| < r\}$$

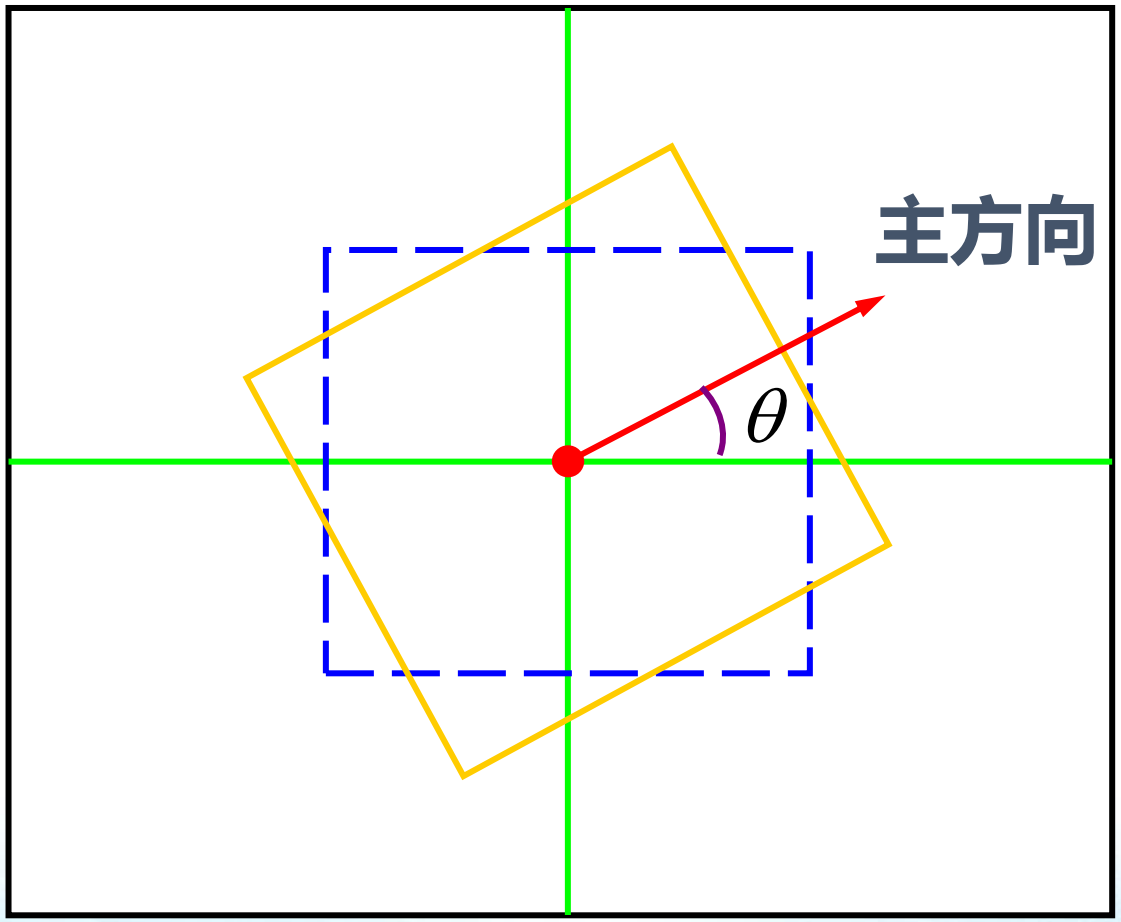
以特征点X为中心的圆形邻域

$$\theta_{main}(X) = \arg \max_{\theta \in [0,2\pi)} \{\sum \left| ||\nabla f(X_i)|| \right| : X_i \in \Omega_r, Arg\left(\nabla f(X_i)\right) = \theta\}$$

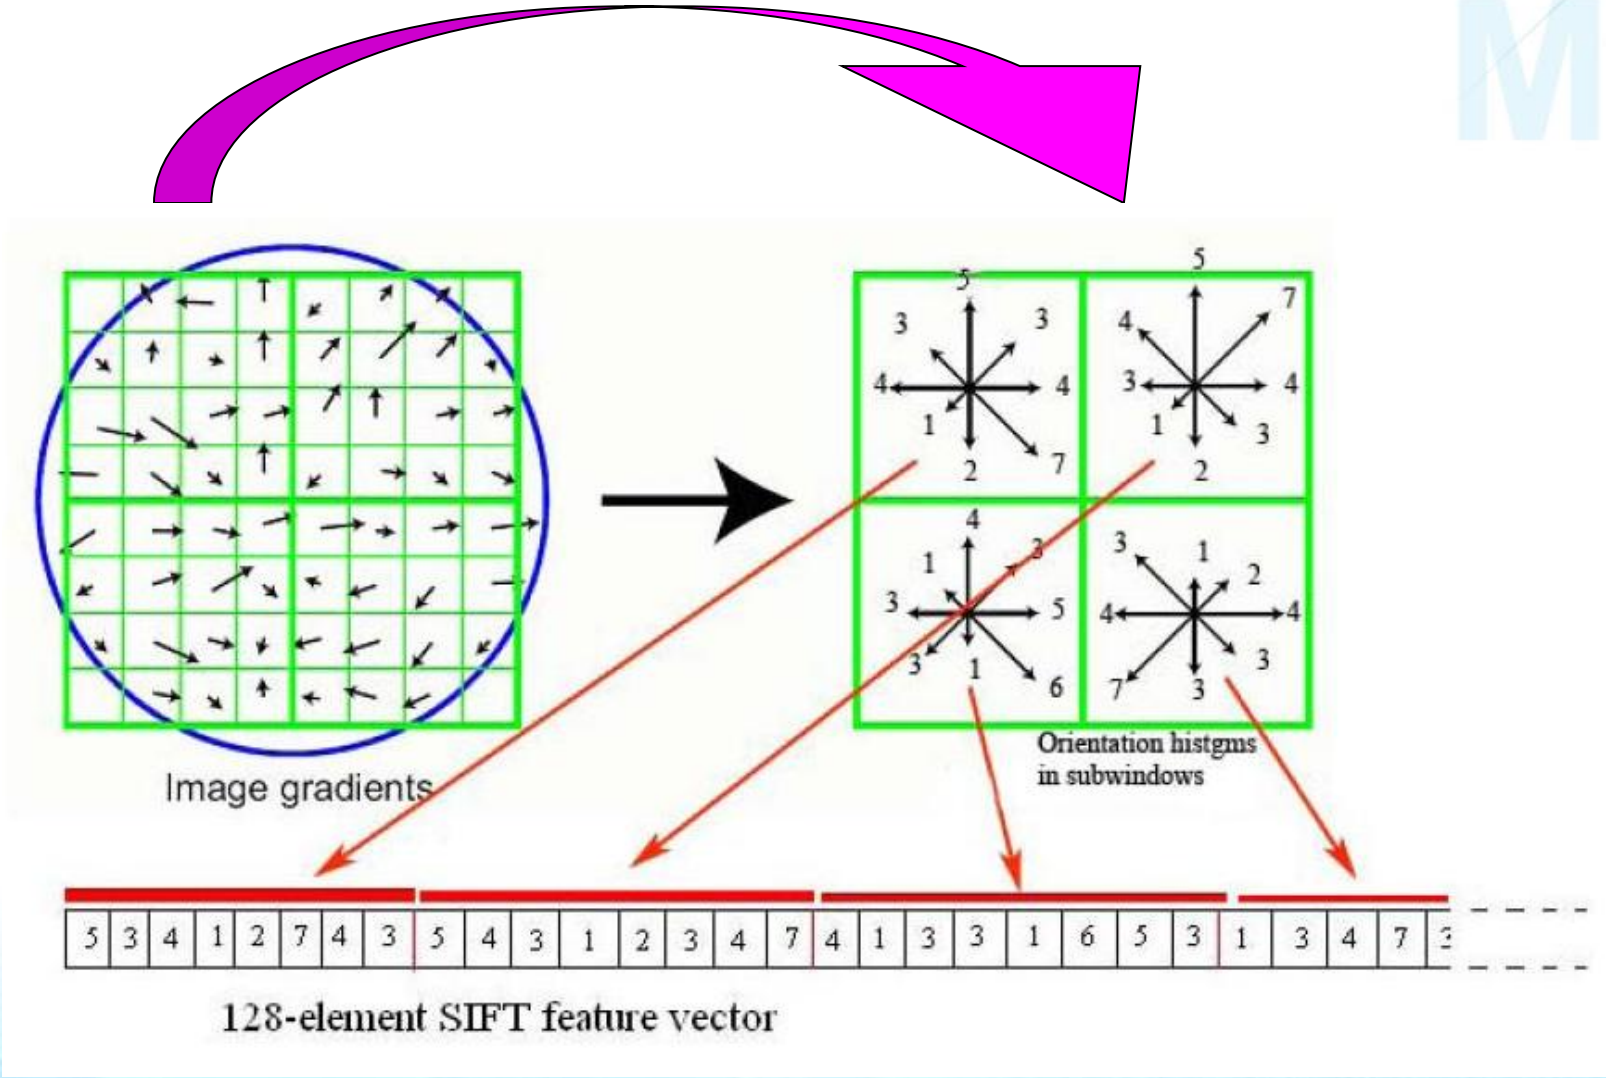
$\nabla f(X_i)$ **梯度**

$Arg\left(\nabla f(X_i)\right)$ **梯度幅角**

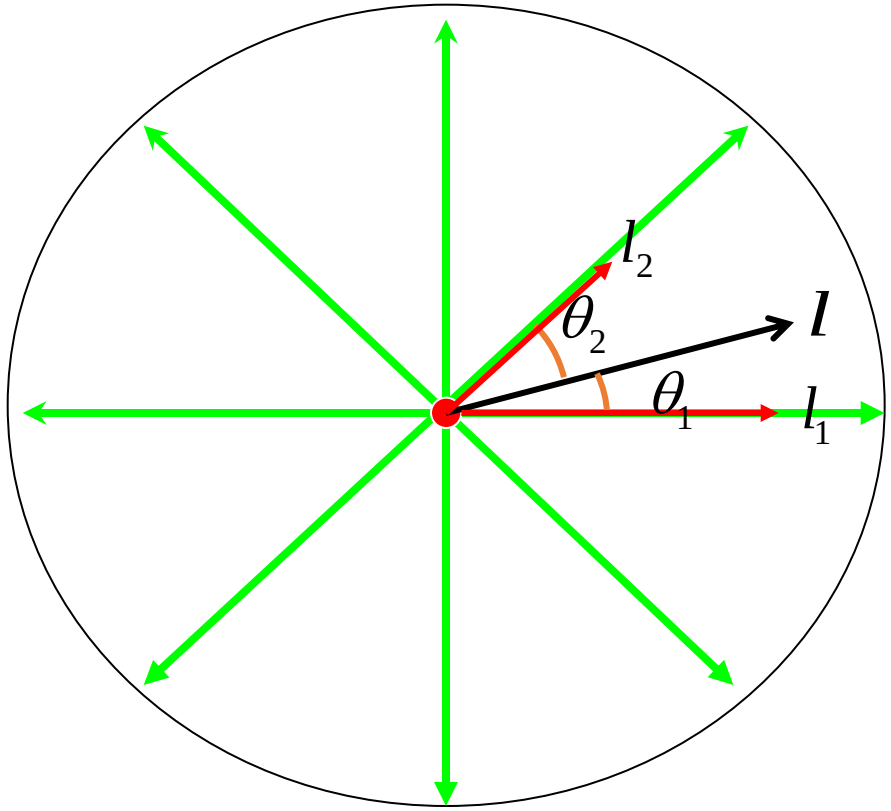
主方向校正



SIFT描述子的构造


Image gradients
Orientation histgms
in subwindows
5 3 4 1 2 7 4 3 5 4 3 1 2 3 4 7 4 1 3 3 1 6 5 3 1 3 4 7
128-element SIFT feature vector

梯度幅值的插值运算

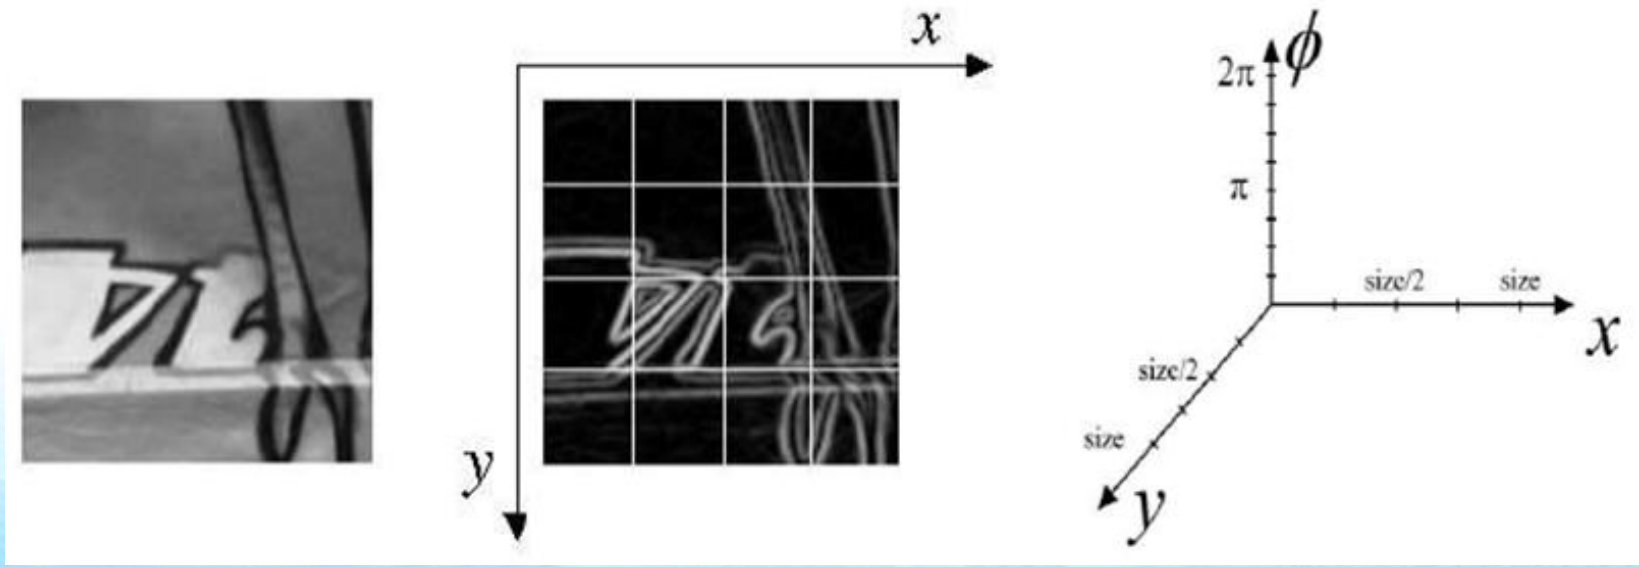


$$l_1 = \frac{\theta_2}{\theta_1 + \theta_2} l$$

$$l_2 = \frac{\theta_1}{\theta_1 + \theta_2} l$$

SIFT描述子的构造

- 三维直方图的计算
  - 将关键点邻域划分为4×4个子区域
  - 梯度方向划分为8个方向
  - 直方图的值为梯度幅值的累加
  - 得到一个4×4×8＝128维向量



SIFT描述子的特点

- SIFT描述子的特点
  - 直方图统计：提高了对图像局部形变的适应能力
  - 子区域划分：弥补了丢失的位置信息，增强辨别力
  - 16×16的邻域和4×4的子区域都进行了类似于高斯函数的加权处理，强化中心区域，淡化边缘区域的影响

SIFT描述子的不变性

- 尺度不变
  - 根据关键点的尺度选取高斯图像和邻域大小
- 旋转不变
  - 将邻域内每点的位置和梯度方向根据关键点的主方向进行旋转
- 适应复杂几何变形
  - 采用分块直方图统计、高斯加权等细节处理
- 适应复杂光照变化
  - 线性光照：归一化128维向量
  - 非线性光照：将128维中所有大于0.2的元素赋值为0.2

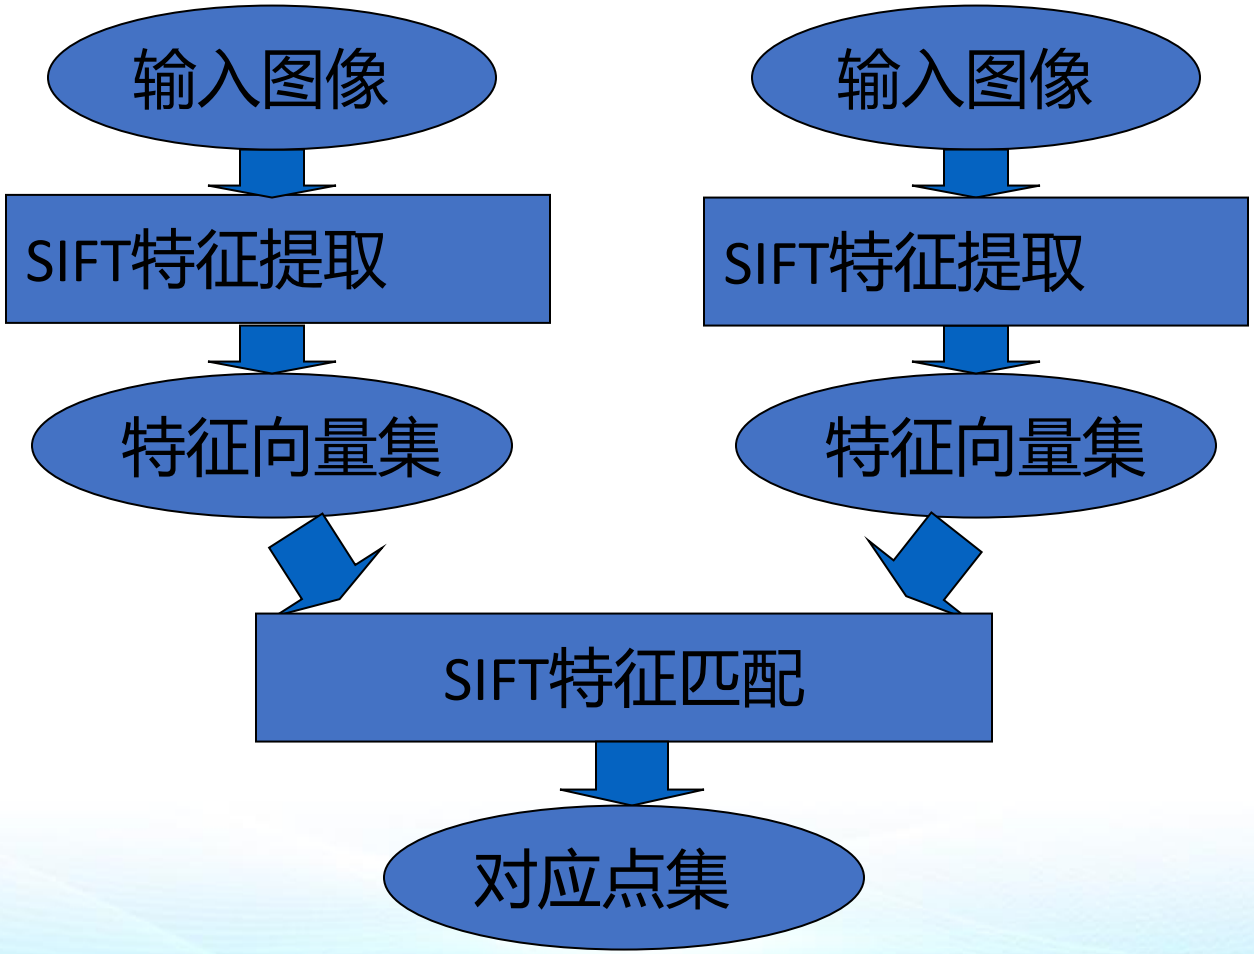
SIFT特征匹配

- 匹配准则
  - NNDR (Nearest Neighbor Distance Ratio)

$$NNDR = \frac{d(m, m_1)}{d(m, m_2)}$$

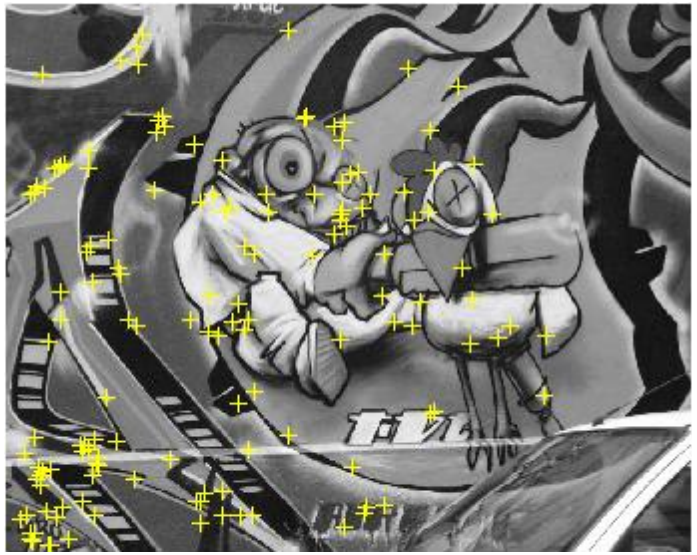
- 搜索策略
  - BBF算法(Best Bin First) (Beis&Lowe, 1997)

SIFT特征匹配



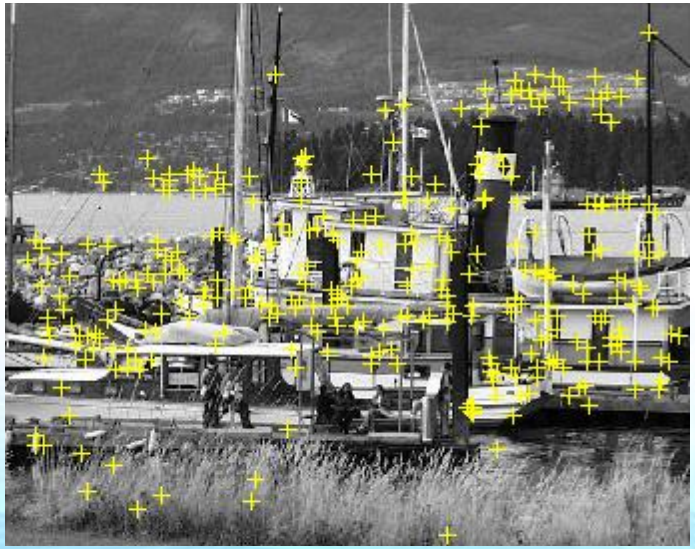
实验结果 - 视角和旋转变化

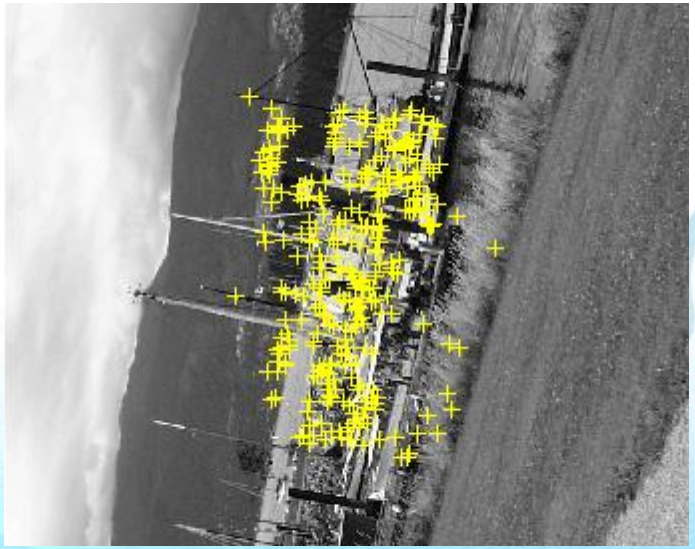
视角变化





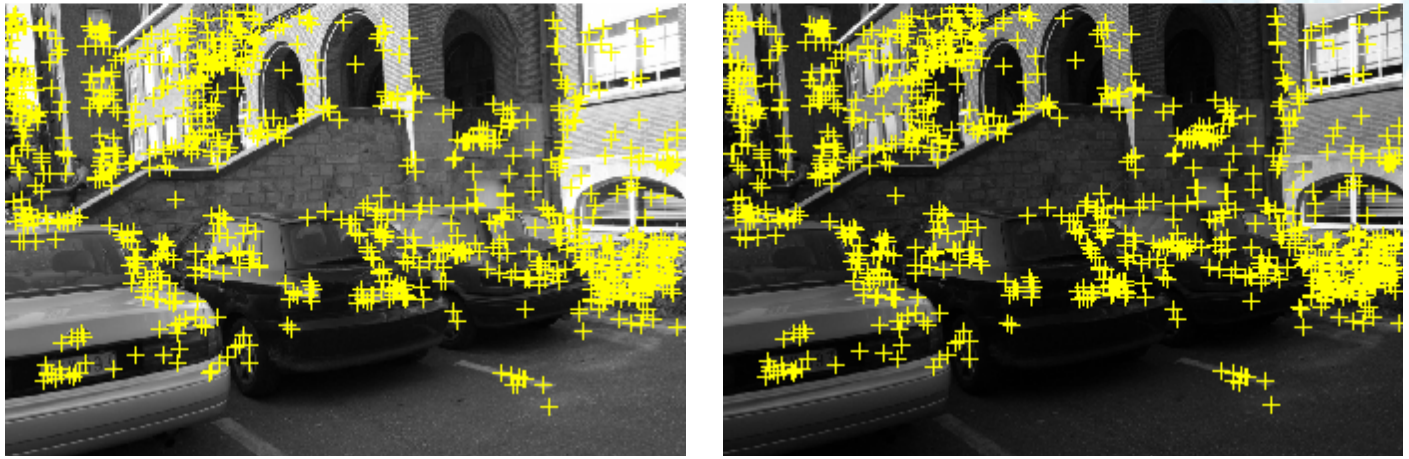
旋转 +
尺度变化



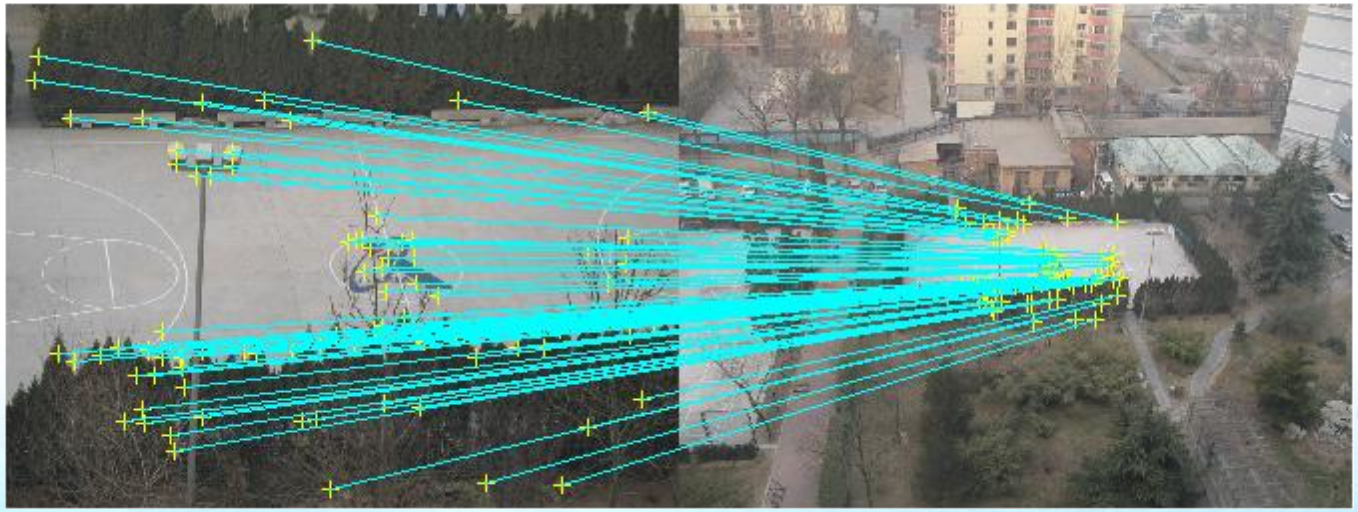


实验结果 - 光照和尺度变化

光照变化



尺度变化



ORB特征

ORB特征

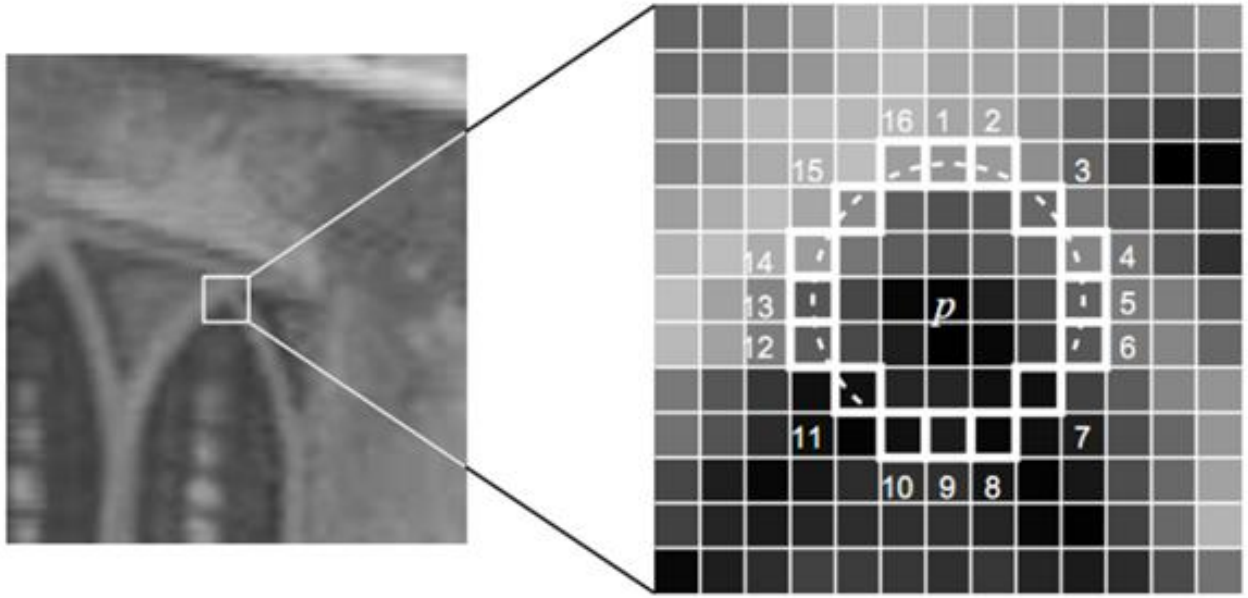
- ORB（Oriented FAST and Rotated BRIEF）
- ORB = FAST + BRIEF（改进的版本）
- 研究动机：快速性、兼顾准确性
- FAST（features from accelerated segment test）
  - 假设：若该点的灰度值比其周围领域内足够多的像素点的灰度值大或者小，则该点可能为角点。

Edward Rosten, Reid Porter, and Tom Drummond, “Faster and better: a machine learning approach to corner detection” in IEEE Trans. Pattern Analysis and Machine Intelligence, 2010, vol 32, pp. 105-119.

ORB特征-FAST

- Fast-N:

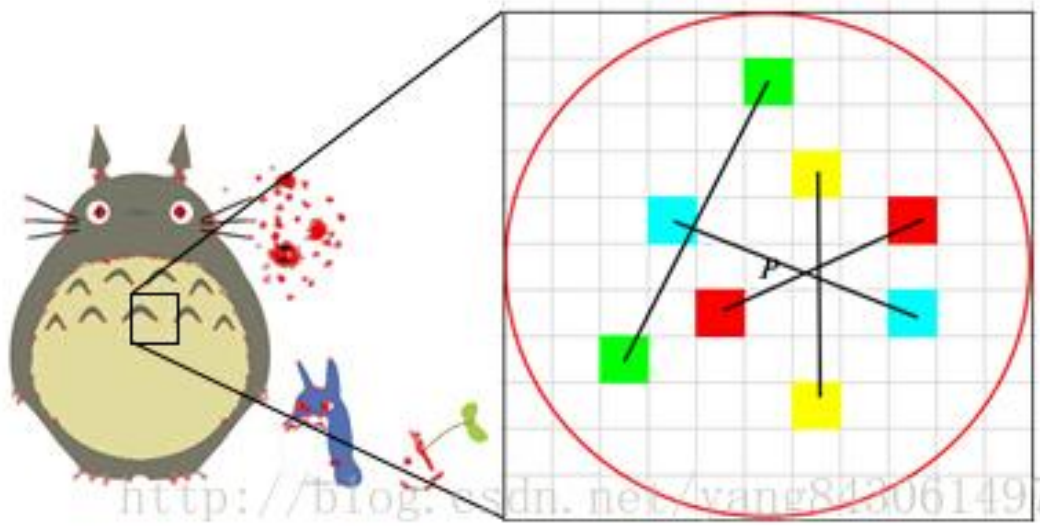
$$N=\sum_{x\,\forall\,(circle(p))}|I(x)-I(p)|>\varepsilon_d$$





ORB特征-BRIEF

- BRIEF: Binary Robust Independent Elementary Features
  - 二进制描述子：高速、低存储
  - 构造方法：在已提取出的特征点的邻域patch中，随机选取若干对像素点，分别比较每对像素点的灰度大小，赋值为1或0，从而构建描述子。



$$\tau(\mathbf{p};\mathbf{x},\mathbf{y}) := \begin{cases} 1 & \text{if } \mathbf{p}(\mathbf{x}) < \mathbf{p}(\mathbf{y}) \\ 0 & \text{otherwise} \end{cases}$$

$$f_{n_d}(\mathbf{p}) := \sum_{1 \le i \le n_d} 2^{i-1}\, \tau(\mathbf{p};\mathbf{x}_i,\mathbf{y}_i)$$

ORB特征-BRIEF

- 匹配：
  - 汉明距离（ Hamming Distance）：在信息论中，两个等长字符串之间的汉明距离是两个字符串对应位置的不同字符的个数。
  - 实例： “1011101”与“1001001”之间的汉明距离是2。
- ORB = FAST + BRIEF（改进的版本）
  - 特征点的处理
  - 多尺度
  - 主方向
  - 课后练习

目 录

一、局部特征匹配

（1）SIFT特征点

（2）ORB特征点

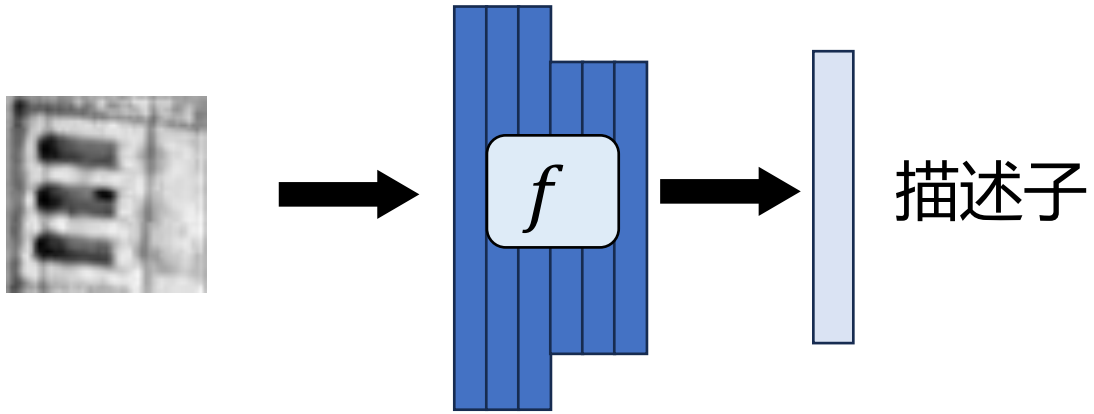
二、特征描述子学习

三、ICP算法

四、鲁棒匹配——RANSAC

TFeat

设$f(\cdot)$为深度网络所代表的映射：输入是以特征点为中心的图像块，输出是d维描述子向量。

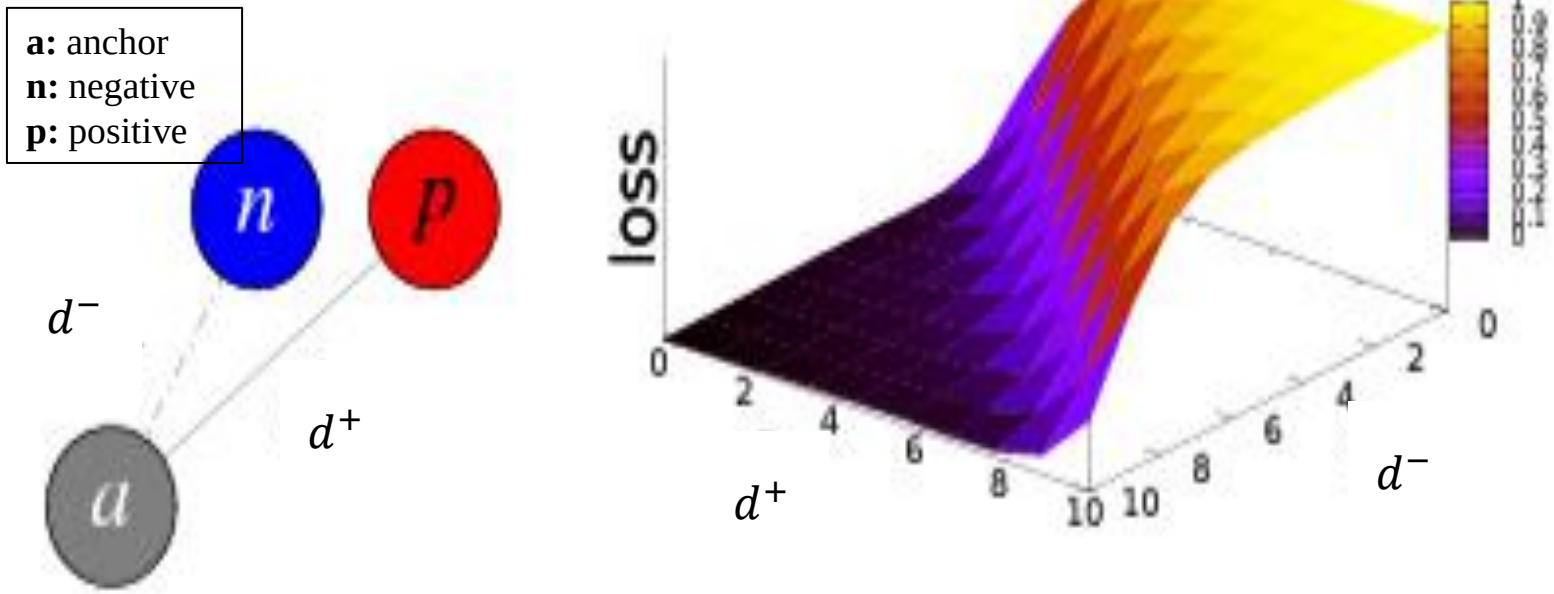


令x_1，x_2为两个图像块，则$||f(x_1)-f(x_2)||_2$代表两者之间描述子的欧氏距离。

描述子学习的目标：使得匹配图像块描述子之间的距离更近，不匹配图像块之间的距离更远。

Balntas V, Riba E, Ponsa D, et al. Learning local feature descriptors with triplets and shallow convolutional neural networks[C]//Bmvc. 2016.

TFeat



TFeat采用三元组边缘损失函数训练（Triplet Margin Loss）：

$$L = \max(0, m + d^+ - d^-)$$

其中，d^+表示正样本对（a-p）之间的距离，d^-表示负样本对（a-n）之间的距离。

Balntas V, Riba E, Ponsa D, et al. Learning local feature descriptors with triplets and shallow convolutional neural networks[C]//Bmvc. 2016, 1(2): 3.

L2-Net: 结构图



输入：以特征点为中心的图像面片patch
输出：128维的单位向量描述子。

- 局部图像面片往往尺寸较小，仅包含了图像的局部信息，因此网络的层数不宜过多，网络每层也不宜过宽。
- 在数值稳定性方面，单位向量比非单位向量更稳定。

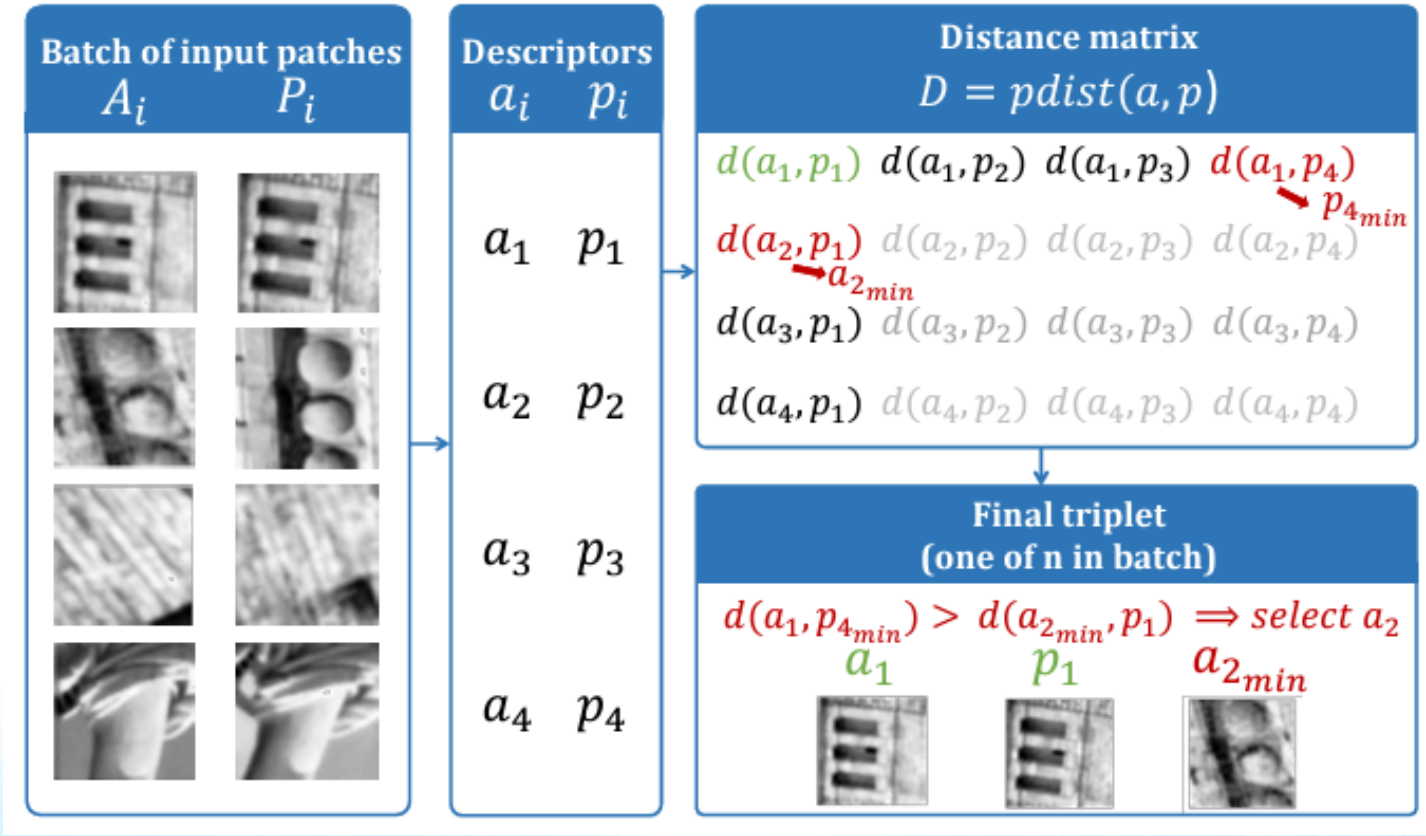
Y. Tian Y. et al., L2-Net: Deep Learning of Discriminative Patch Descriptor in Euclidean Space, CVPR 2017

HardNet

$$L = \max(0, m + d^+ - d^-)$$

基于三元组损失函数，提出了**hardest-in-batch**的负样本采样策略。

如下图所示，即选择每个batch内与正样本之间距离最近的图像块作为负样本。

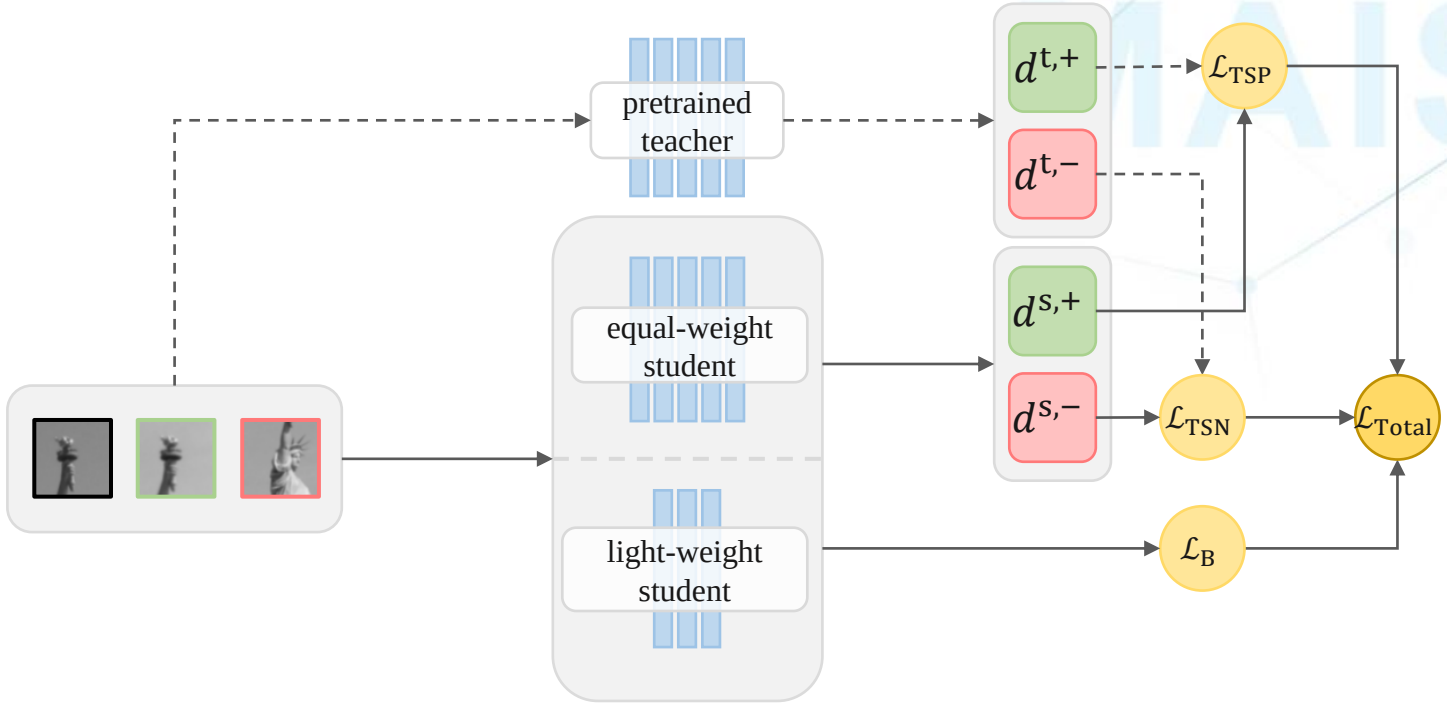


Mishchuk A, Mishkin D, Radenovic F, et al. Working hard to know your neighbor's margins: Local descriptor learning loss[J]. Advances in neural information processing systems, 2017, 30.

DesDis: *Des*criptor *Dis*tillation

基本原理：

- **知识蒸馏**
- **“教师-学生”正则子**

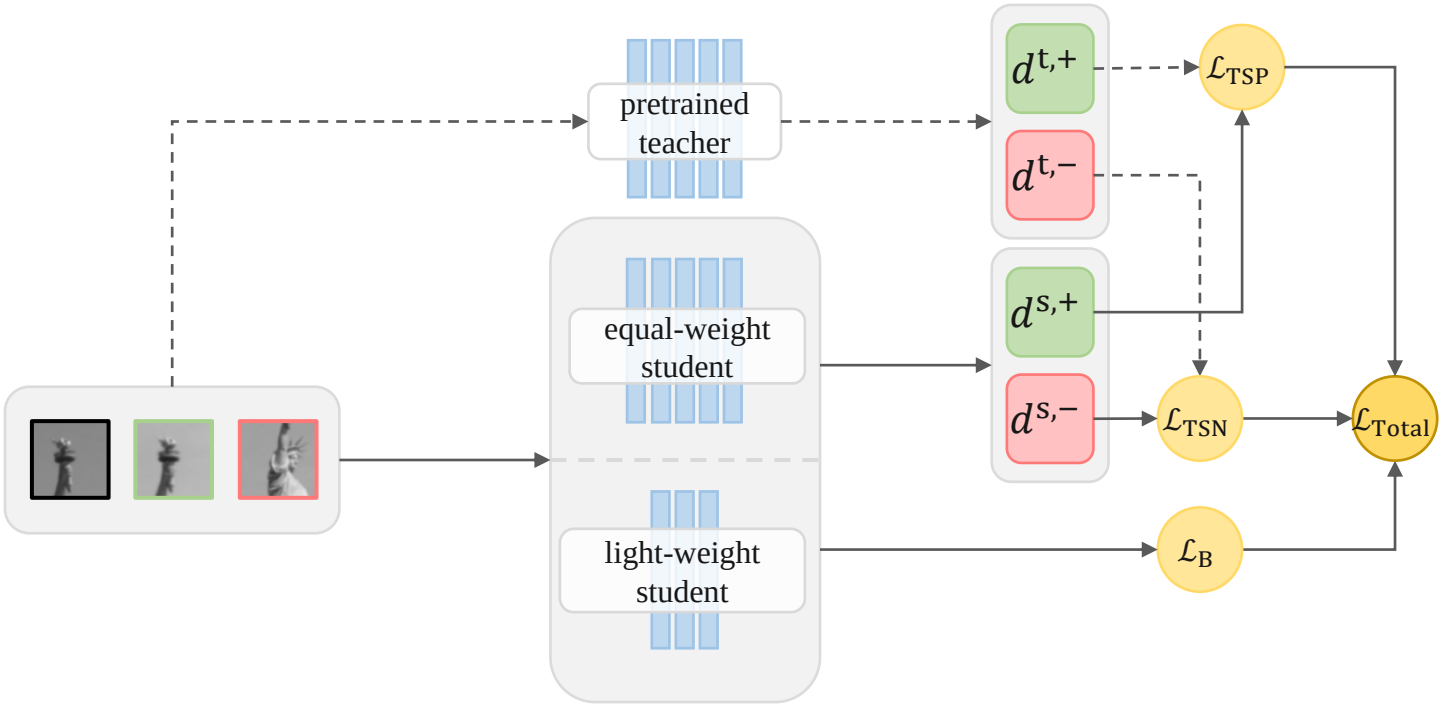


给定预训练的教师模型：

- **等重量蒸馏：**得到性能更好的学生模型
- **轻量级蒸馏：**模型压缩

Y. Liu and Q.Dong, Descriptor Distillation: a Teacher-Student-Regularized Framework for Learning Local Descriptors, International Journal of Computer Vision, 132, 3787-3805, 2024.

DesDis: *Des*criptor *Dis*tillation



总损失函数：$L = L_B + \alpha_p L_{TSP} + \alpha_n L_{TSN}$，其中，$L_B$为基本损失项（与教师网络采用同一损失），$L_{TSP} = (d_t^+ - d_s^+)^2$ $L_{TSP} = (d_t^- - d_s^-)^2$分别为“教师-学生”正则子，$d_t^+, d_s^+$分别为教师与学生预测的正样本间距离；$d_t^-, d_s^-$分别为教师与学生预测的负样本间距离。

Results on Brown

COMPARATIVE EVALUATION ON THE BROWN DATASET [26]. NUMBERS ARE FALSE POSITIVE RATE AT 95% RECALL. THE BEST RESULTS ARE IN **BOLD**. 'DESDIS-' DENOTES THE DERIVED STUDENT MODEL TRAINED UNDER THE PROPOSED DESDIS FRAMEWORK.

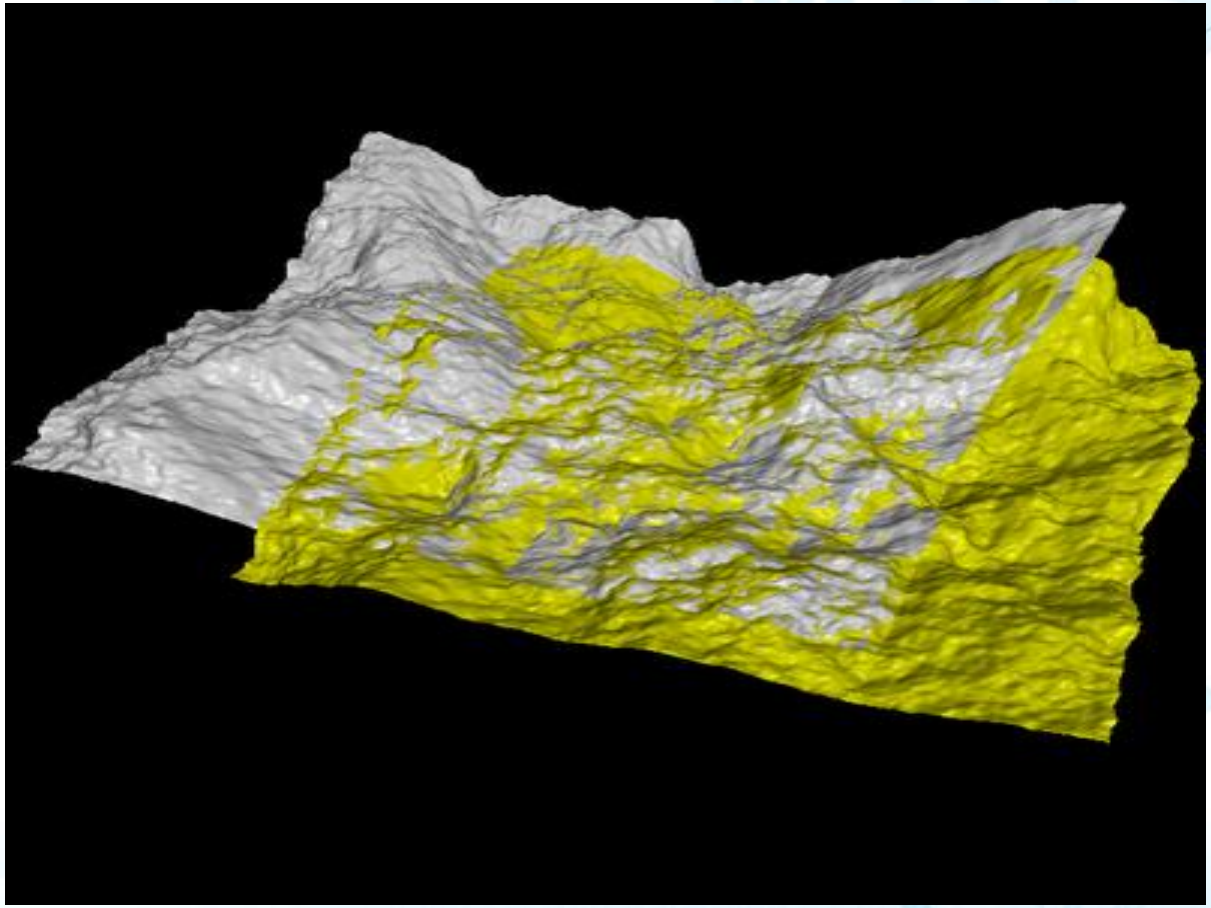
Train	ND	YOS	LIB	YOS	LIB	ND	Mean
Test	LIB		ND		YOS		
SIFT [9]	29.84		22.53		27.29		26.55
MatchNet [33]	7.04	11.47	3.82	5.65	11.6	8.70	8.05
TFeat [12]	7.39	10.13	3.06	3.80	8.06	7.24	6.64
L2Net [34]	2.36	4.70	0.72	1.29	2.57	1.71	2.22
DOAP [35]	1.54	2.62	0.43	0.87	2.00	1.21	1.45
Equal-Weight							
HardNet [13]	1.49	2.51	0.53	0.78	1.96	1.84	1.51
DesDis-HardNet	**1.31**	**2.03**	**0.48**	**0.72**	**1.54**	**1.31**	**1.23**
SOSNet [15]	1.08	2.12	**0.35**	0.67	1.03	0.95	1.03
DesDis-SOSNet	**1.02**	**1.91**	0.36	**0.60**	**0.96**	**0.82**	**0.95**
HyNet [16]	0.89	**1.37**	0.34	0.61	0.88	0.96	0.84
DesDis-HyNet	**0.86**	**1.37**	**0.29**	**0.48**	**0.70**	**0.60**	**0.71**
Light-Weight							
DesDis-8†	4.06	5.61	1.69	1.88	4.96	3.74	3.66
DesDis-8	**3.95**	**5.23**	**1.46**	**1.68**	**4.69**	**3.71**	**3.45**
DesDis-16†	**2.35**	3.77	0.77	1.13	2.97	2.18	2.20
DesDis-16	2.37	**3.15**	**0.72**	**1.05**	**2.59**	**2.06**	**1.99**
DesDis-24†	2.04	2.96	0.63	0.96	2.06	1.73	1.73
DesDis-24	**1.91**	**2.69**	**0.59**	**0.88**	**1.87**	**1.69**	**1.61**
DesDis-32†	1.81	2.86	0.55	0.90	2.01	1.69	1.64
DesDis-32	**1.52**	**2.36**	**0.54**	**0.81**	**1.68**	**1.48**	**1.39**

目 录

一、局部特征匹配
（1）SIFT特征点
（2）ORB特征点
二、特征描述子学习
三、ICP算法
四、鲁棒匹配——RANSAC

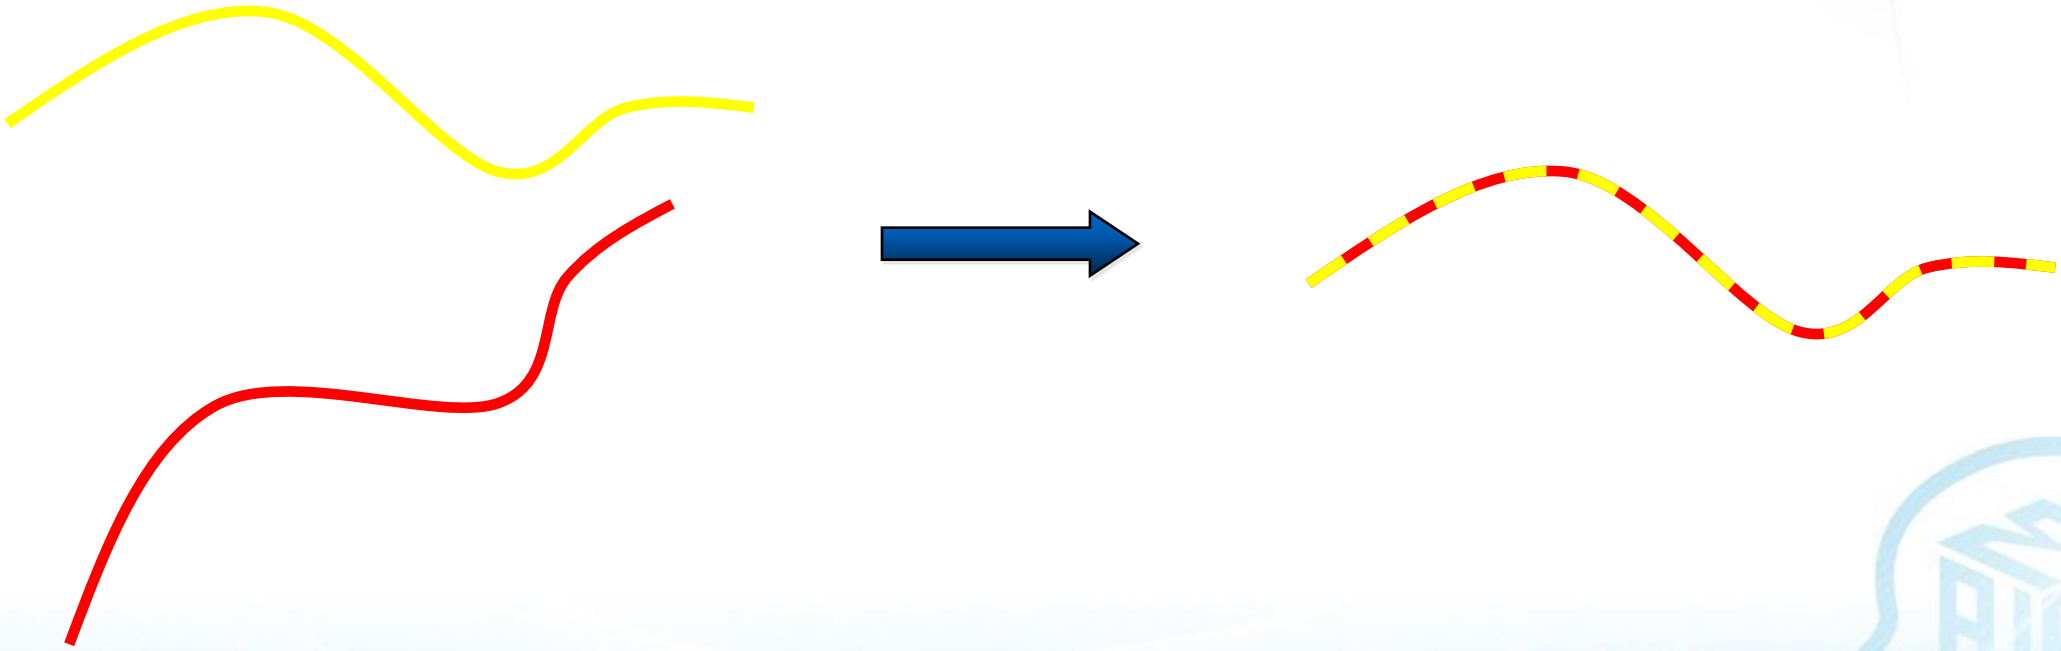
研究背景

- ICP(Iterative Closest Point)：
  - 目标：实现两组点集之间的匹配
  - 示例：对齐两个相互交叠的曲面



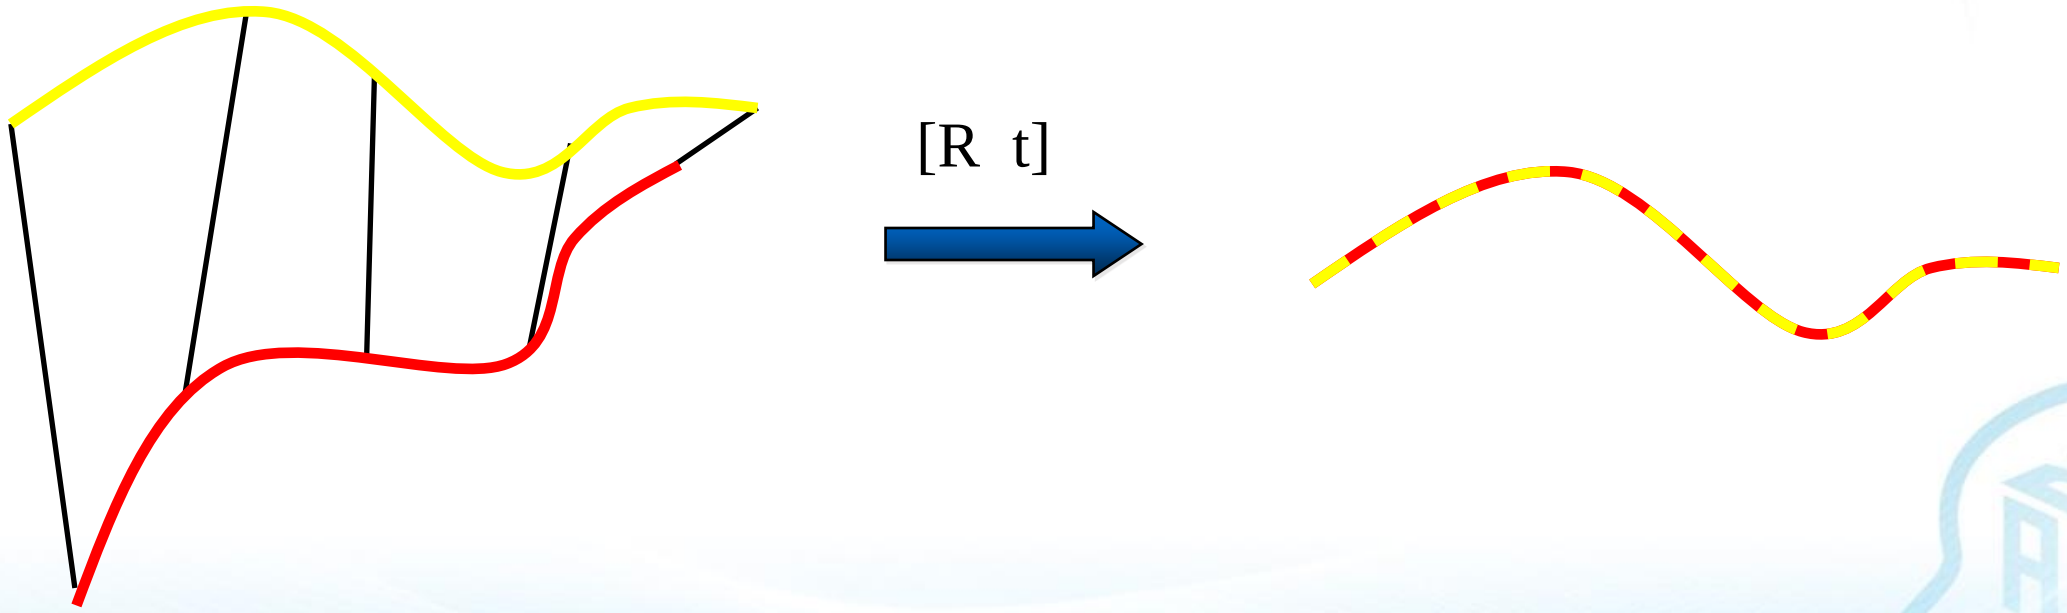
研究背景

- 对齐两条相互交叠的曲线？



问题

- 如果知道正确的点对应，那么两个点集之间的相对旋转和平移有闭式解



基本思路

- 已知：两个**对应点**集合

$$X = \{x_1, x_2, x_3, \dots, x_n\} \qquad P = \{p_1, p_2, p_3, \dots, p_n\}$$

- 求解：旋转矩阵R和平移向量t，使得

$$E(R,t) = \arg\min_{R,t} \frac{1}{n} \sum_{i=1}^{n} ||x_i - Rp_i - t||^2$$

求解最优变换

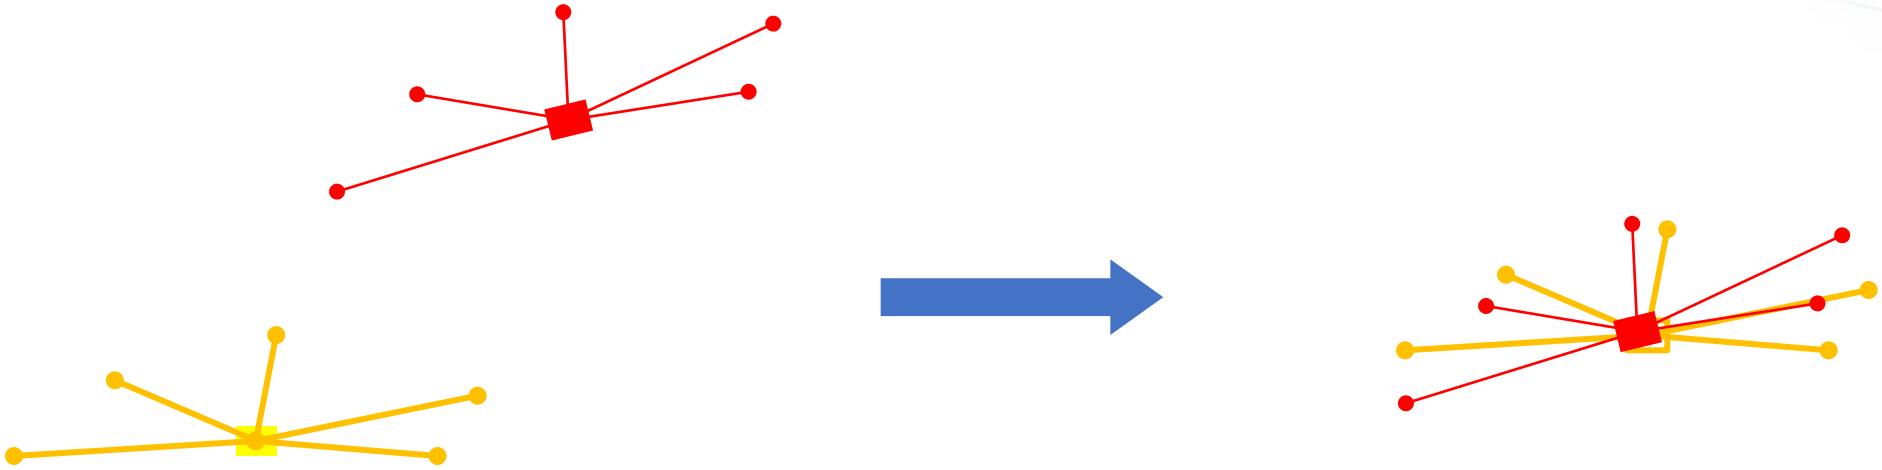
- 计算两个点集X, P的质心

$$\mu_x = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad \mu_p = \frac{1}{n}\sum_{i=1}^{n} p_i$$

- 从两个点集中分别减去对应的质心

$$X' = \{x_i - \mu_x\} = \{x_i'\} \qquad P' = \{p_i - \mu_p\} = \{p_i'\}$$

求解最优变换



求解最优变换

- 利用SVD分解求最优变换

$$W = \sum_{i=1}^{n} x_i' p_i'^T \quad \Rightarrow \quad W = U \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & \sigma_3 \end{bmatrix} V^T$$

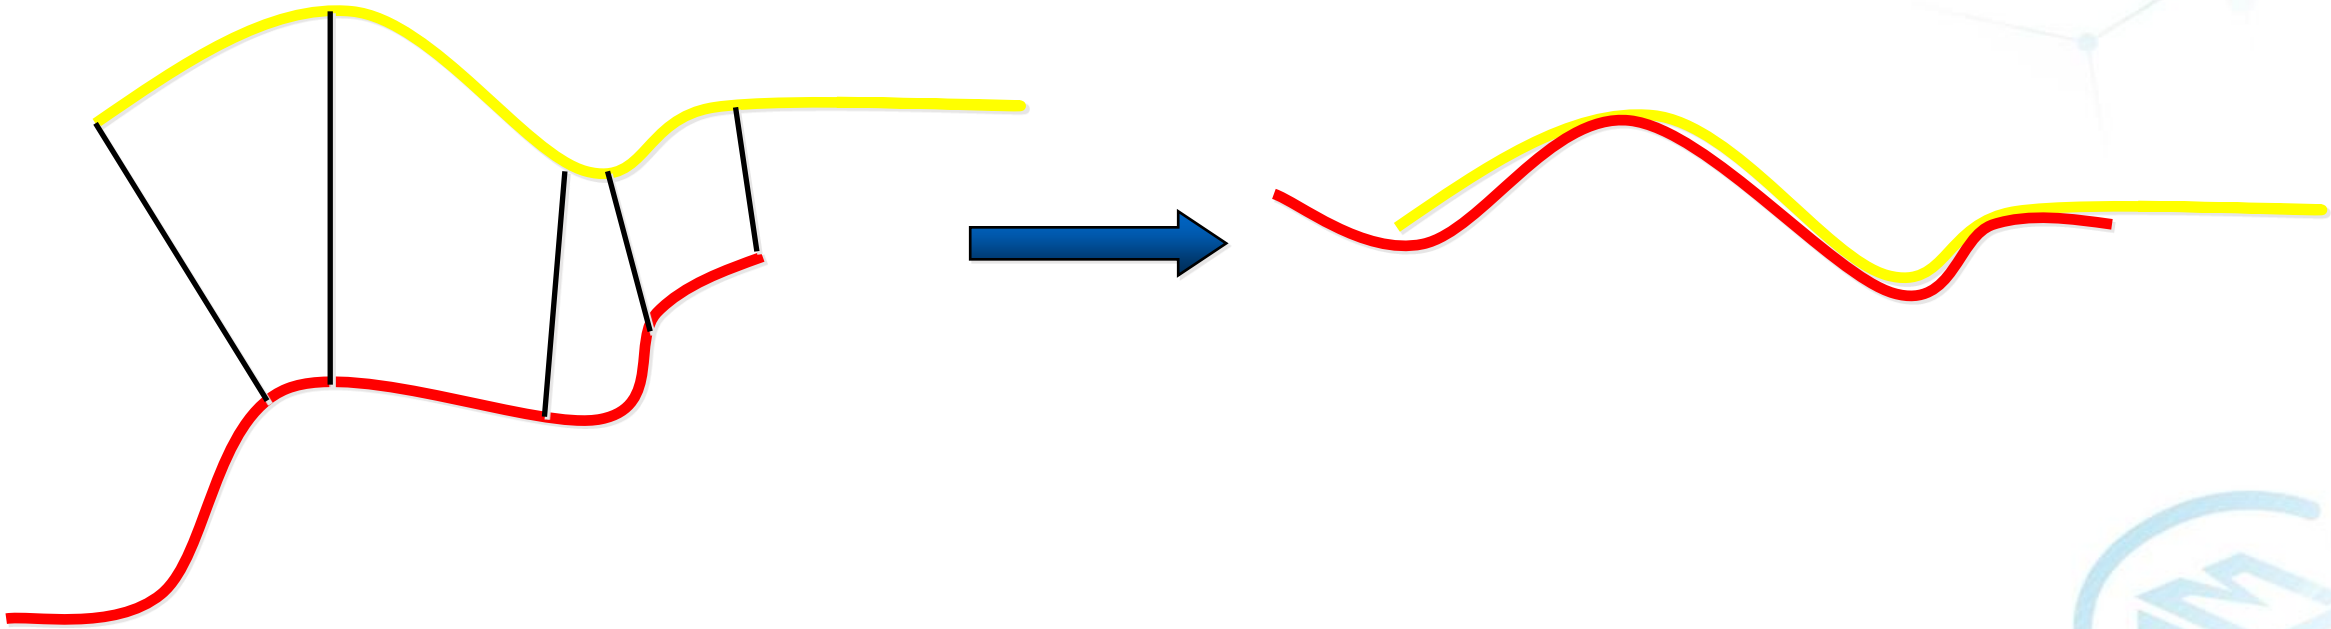
- 如果rank$(W) = 3$，$E(R, t)$ 的最优解是唯一的

$$W = UV^T \qquad t = \mu_x - R\mu_p$$

三维数据点对应

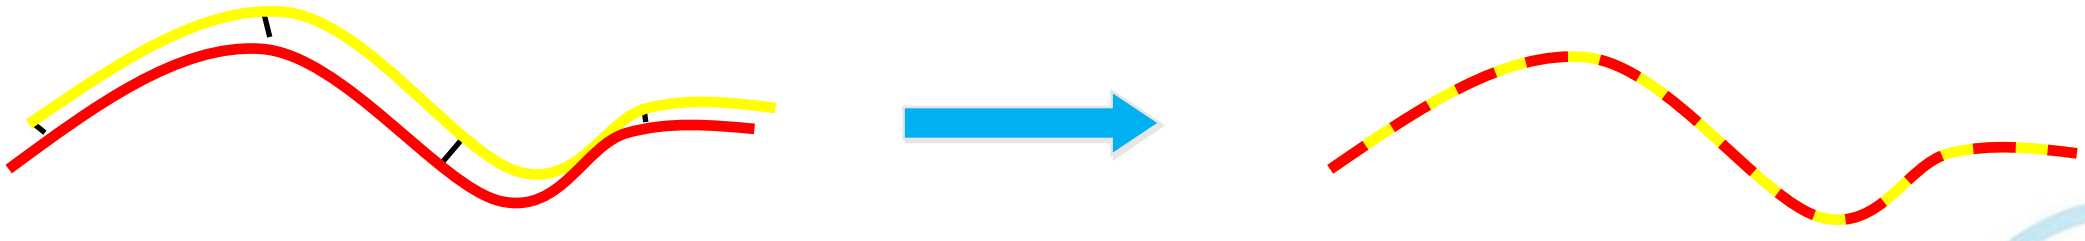
- 如何寻找对应点?
  - 用户输入?
  - 特征检测?
- 在ICP中，假设“**最近**”的点为对应点

三维数据点对应

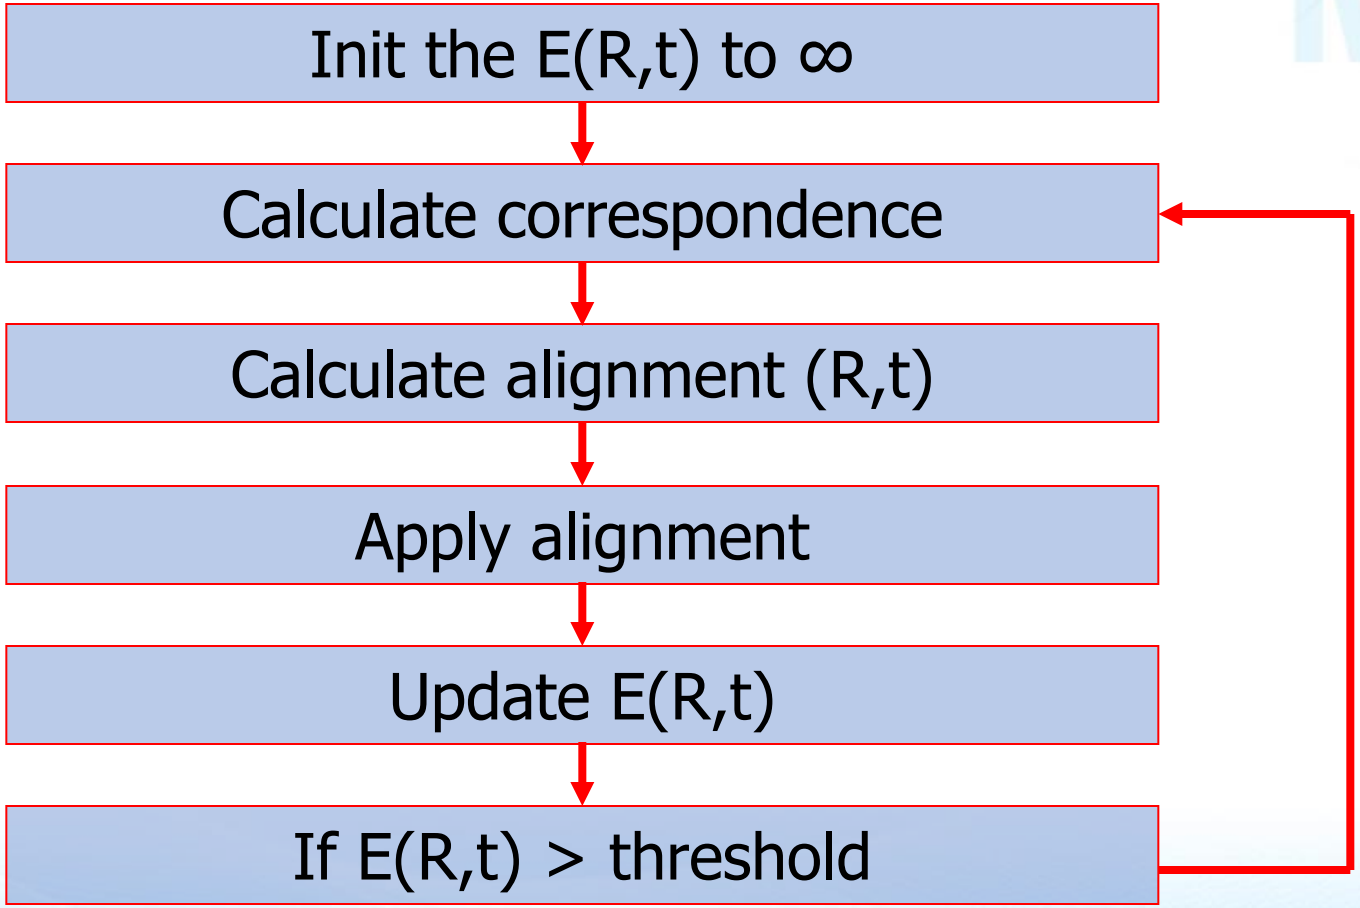


三维数据点对应

- Iterated Closest Points (ICP) [Besl & McKay 92]
- 如果初始点“足够的近”，可以保证收敛性



ICP算法


Init the E(R,t) to ∞
Calculate correspondence
Calculate alignment (R,t)
Apply alignment
Update E(R,t)
If E(R,t) > threshold

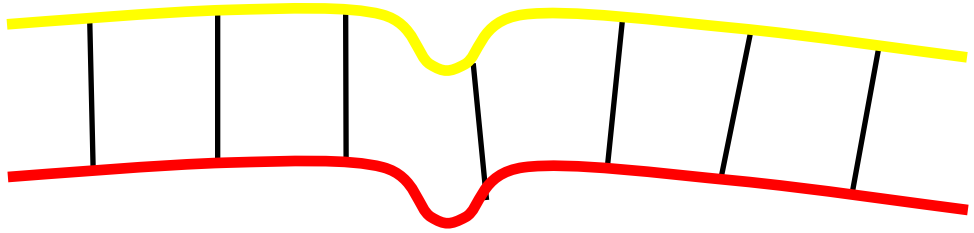
ICP算法

- 点集选取(selecting)
- 点集匹配(matching)
- 点集对应权重(weighting)

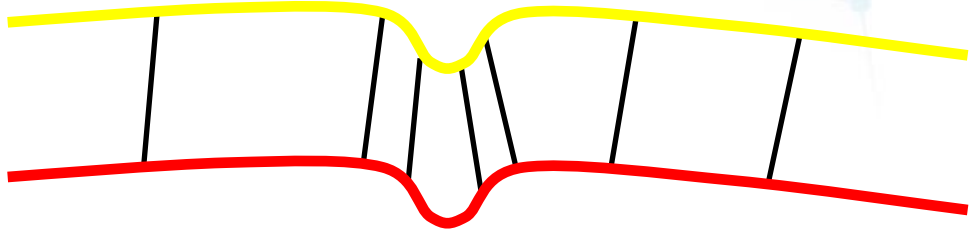
点集选取

- 选择所有点
- 均匀采样(Uniform Sampling)
- 随机采样(Random Sampling)
- 法方向空间均匀采样(Normal-space Uniform Sampling)

点集选取



Uniform Sampling



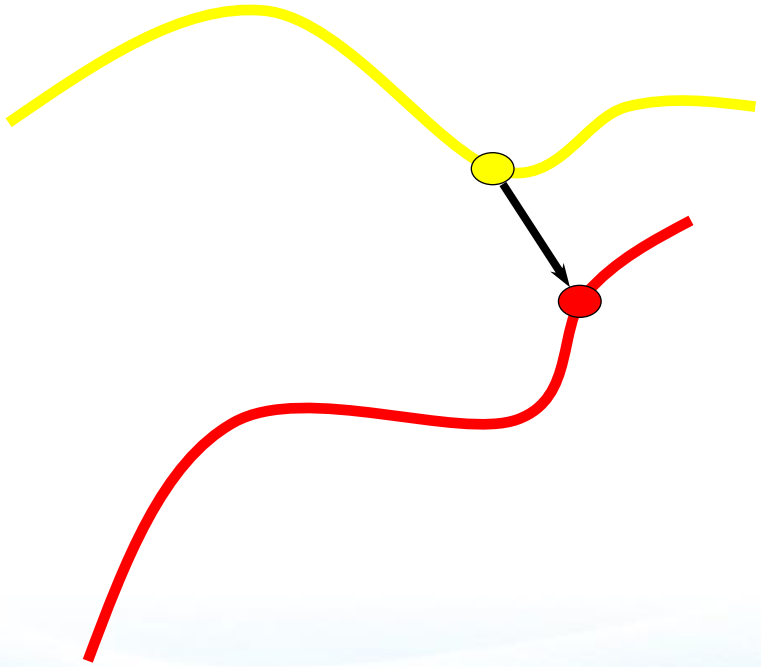
Normal-Space Uniform Sampling

点集匹配

- 最近邻点 (Closest point)
- 法方向最近邻点 (Normal shooting)
- 投影法 (Projection)

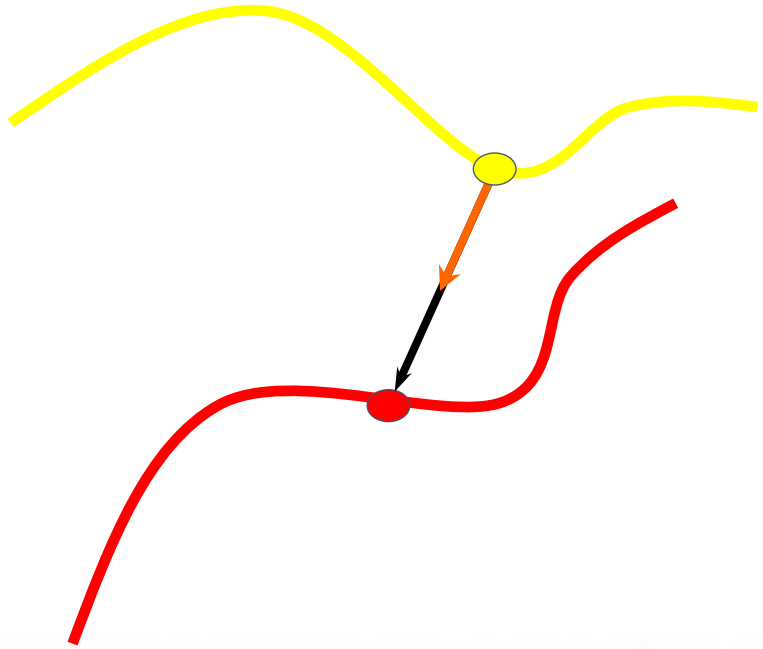
最近邻点

- 稳定，但速度慢



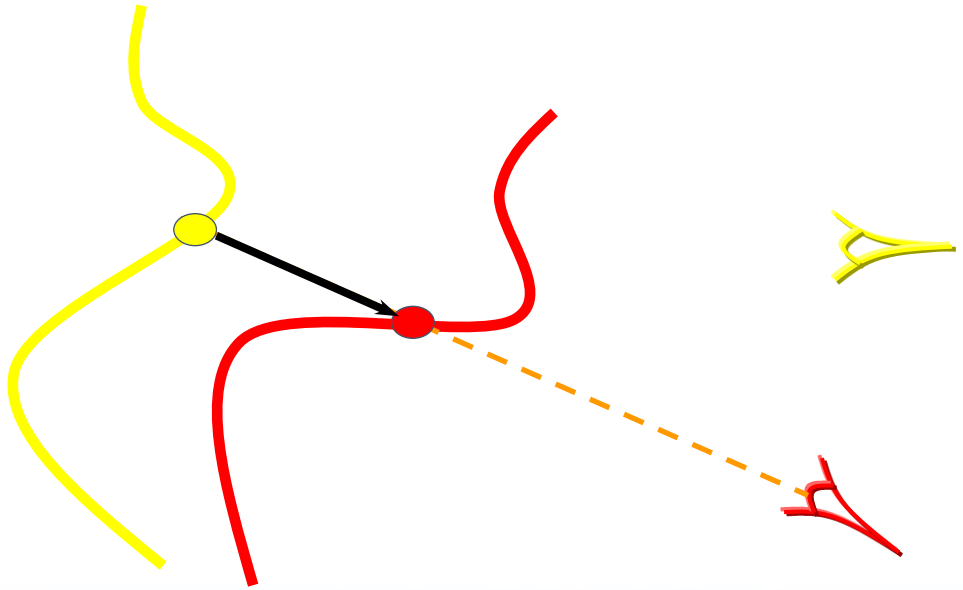
法方向最近邻点

- 平滑曲面效果好，但对噪音敏感



投影法

- 搜索对应点速度快



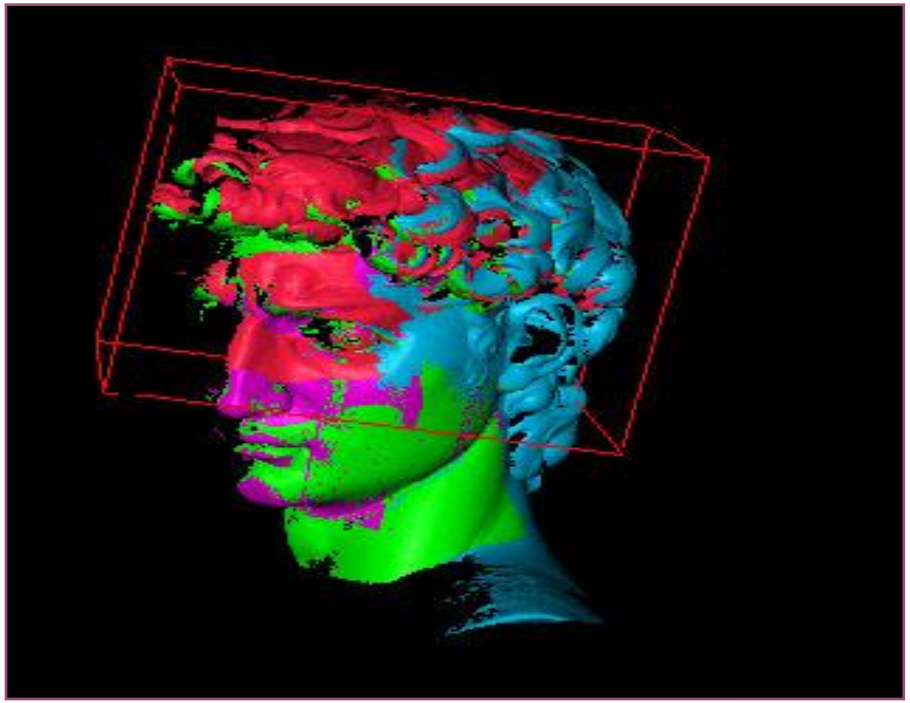
点集对应权重

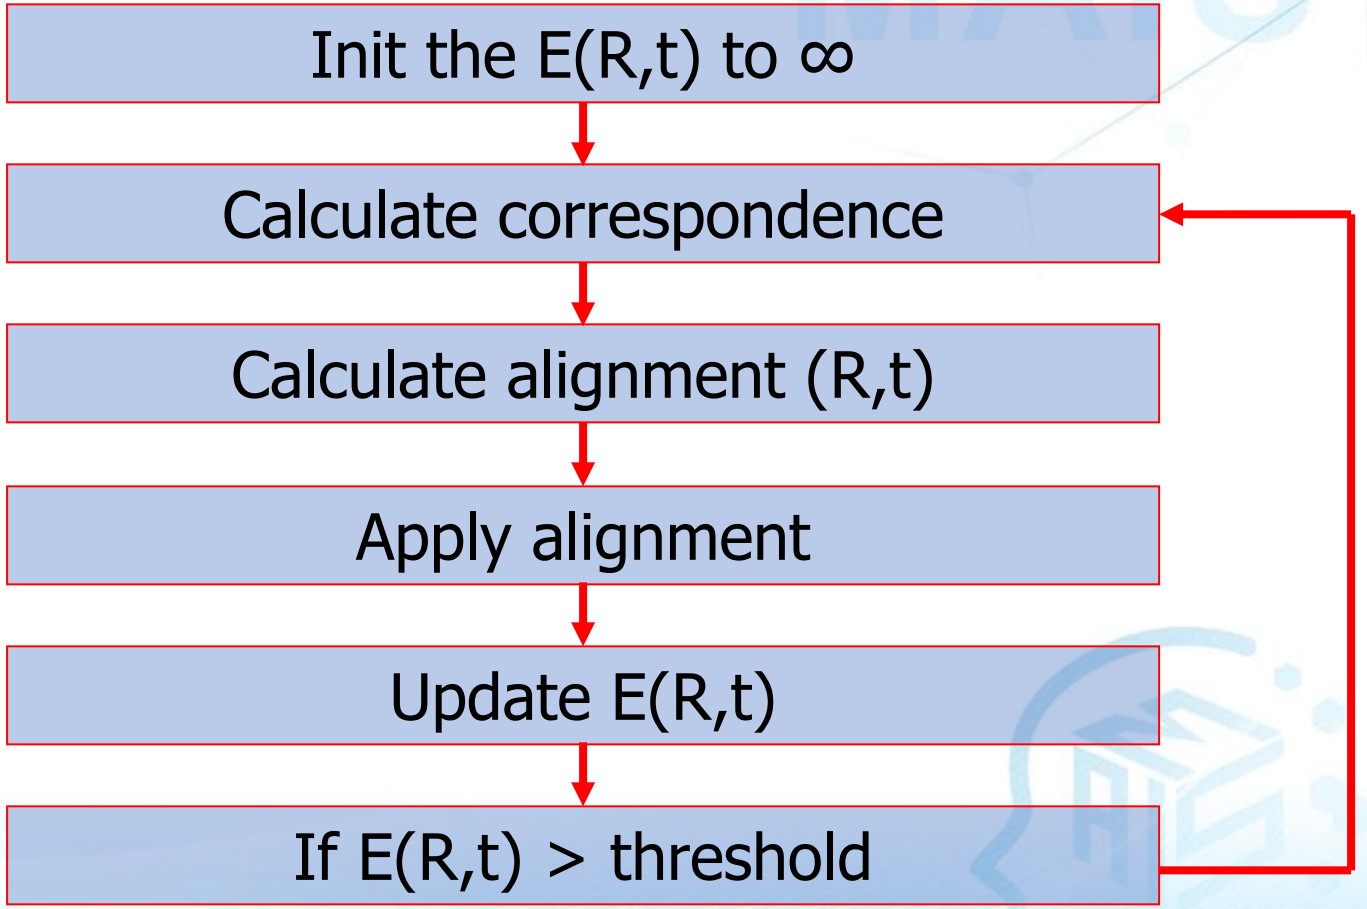
$$E(R,t) = \arg\min_{R,t} \frac{1}{n} \sum_{i=1}^{n} ||x_i - Rp_i - t||^2$$

$$E(R,t) = \arg\min_{R,t} \frac{1}{n} \sum_{i=1}^{n} weight_i ||x_i - Rp_i - t||^2$$

- 固定权重 $weight_i = 1$
- 距离权重 $weight_i = 1 - \frac{Dist(x_i - p_i)}{Dist_{max}}$
- 法方向权重 $weight_i = n_{x_i} n_{p_i}$

ICP小节




Init the E(R,t) to ∞
Calculate correspondence
Calculate alignment (R,t)
Apply alignment
Update E(R,t)
If E(R,t) > threshold

目 录

一、局部特征匹配

（1）SIFT特征点

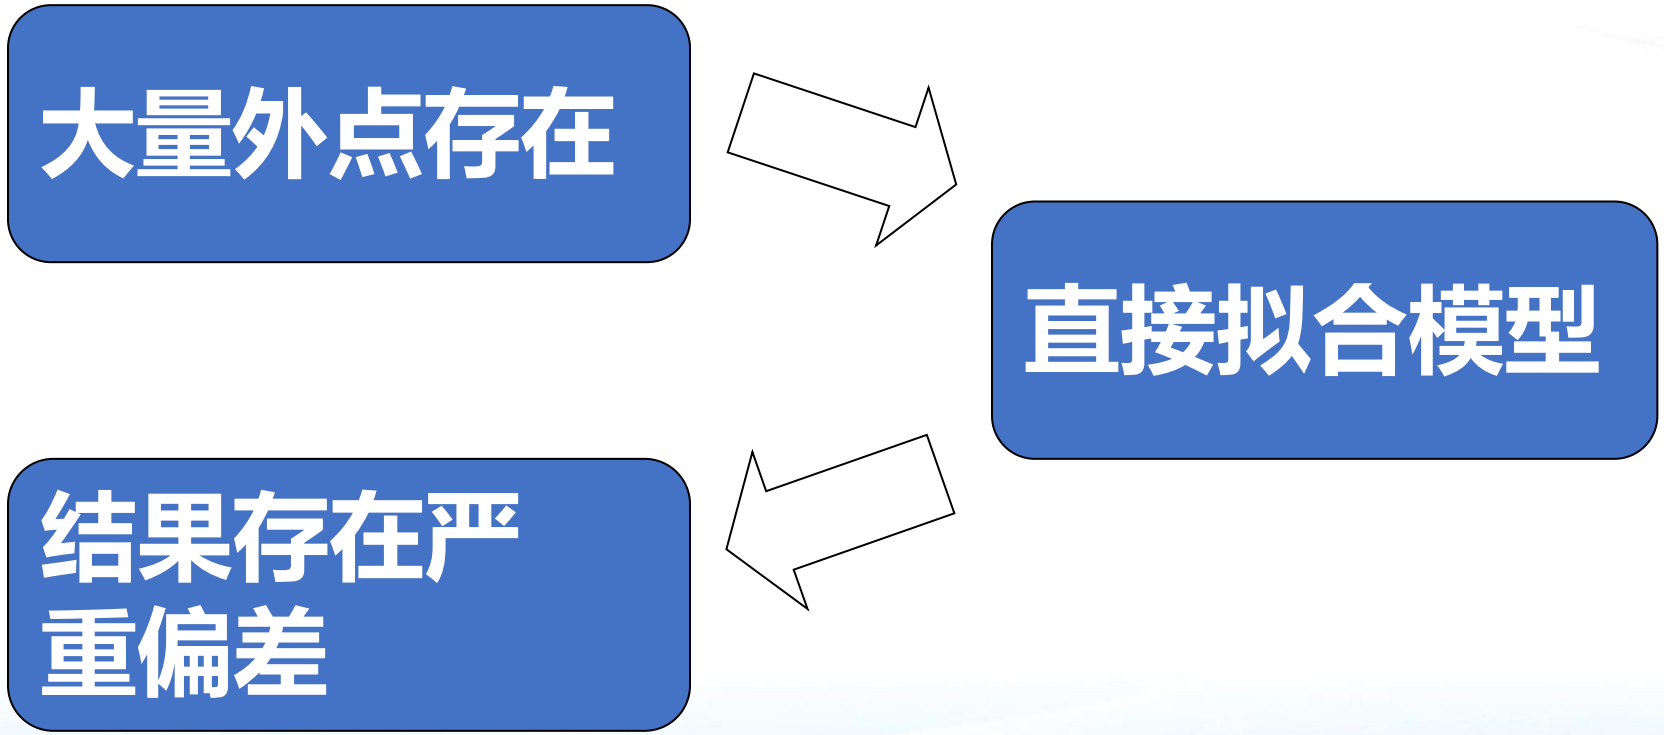
（2）ORB特征点

二、特征描述子学习

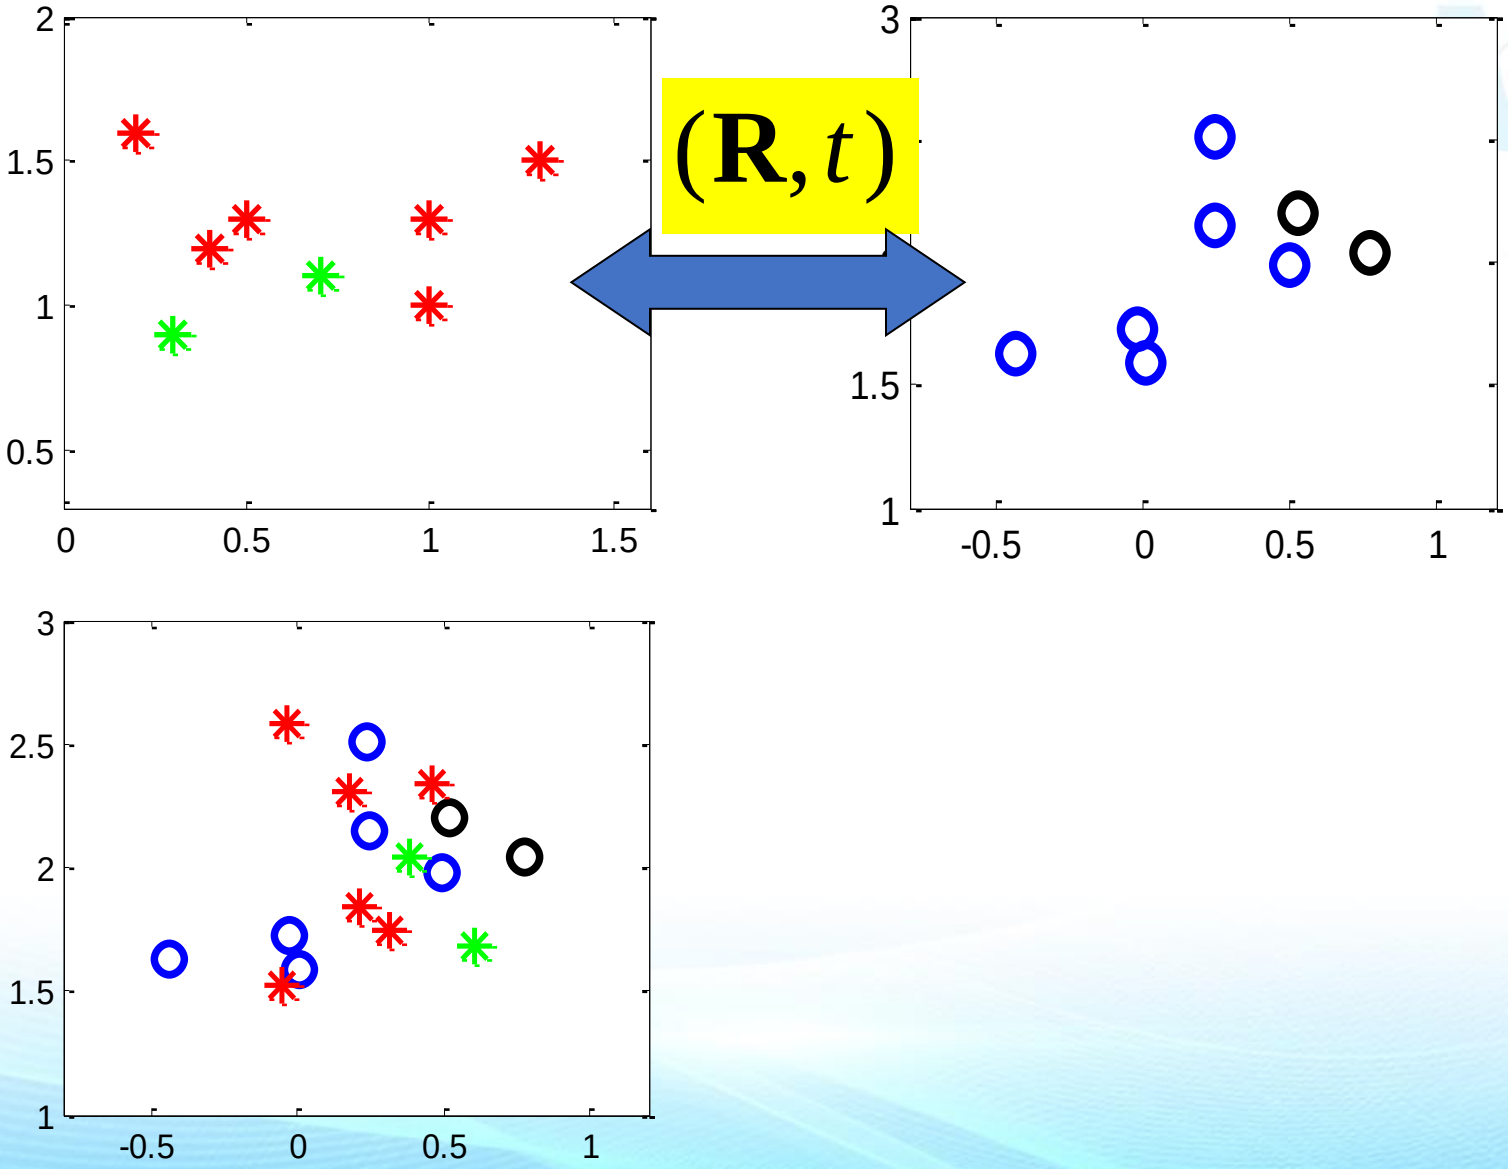
三、ICP算法

四、鲁棒匹配——RANSAC

鲁棒匹配问题特点



示例问题



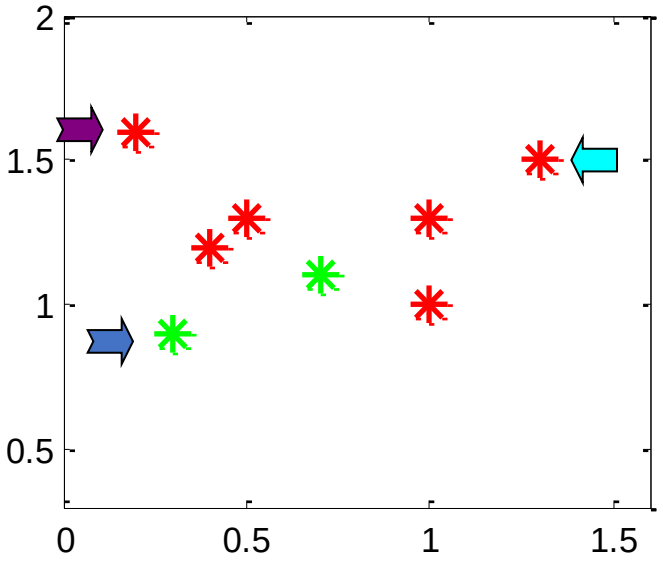
问题如何解决?

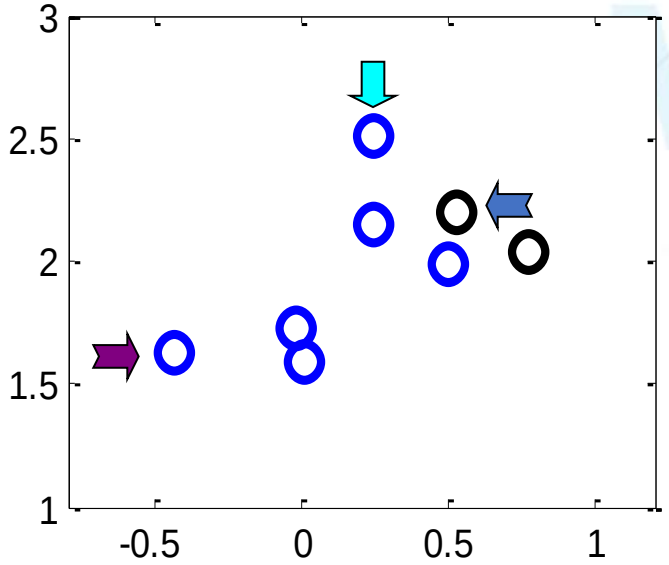
- 需要一种算法，能排除外点干扰
- 用排除外点的数据，重新拟合模型，得到最终结果

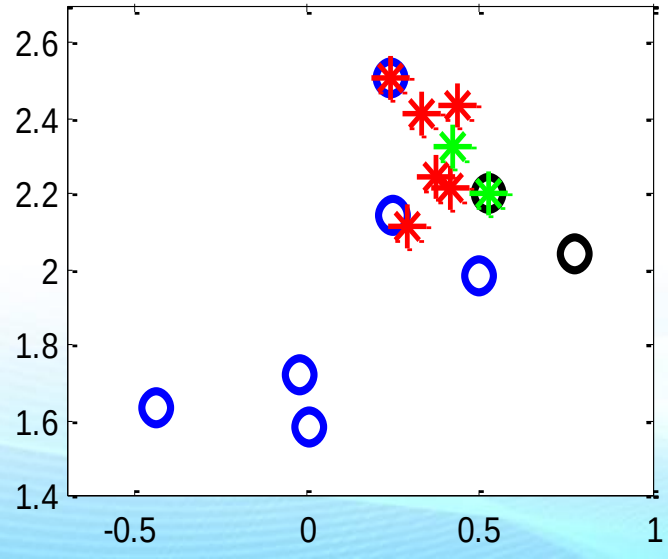
RANSAC估计模型M的一般步骤

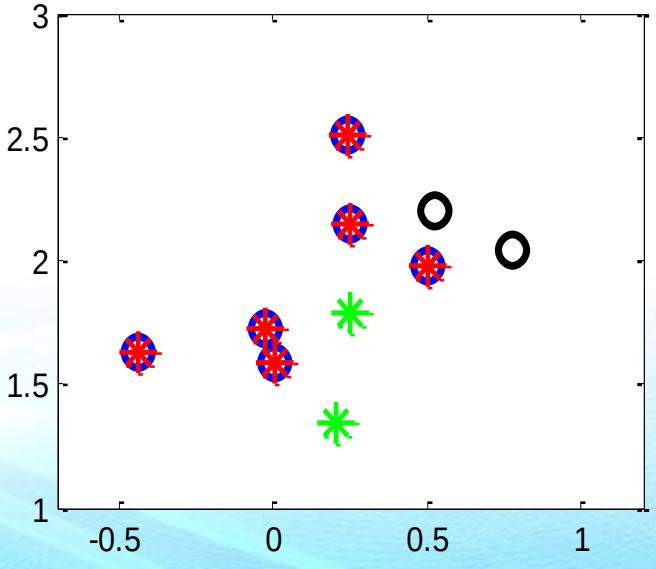
- 确定求解模型M，所需要的最小数据点的个数*n*。由*n*个数据点组成的子集称为模型M的一个样本；
- 从数据点集D中随机地抽取一个样本J，由该样本计算模型的一个实例 $M_p(J)$，确定与 $M_p(J)$ 之间几何距离< 阈值 *t* 的数据点所构成的集合，并记为 $S(M_p(J))$，称为实例 $M_p(J)$ 的一致集；
- 如果在一致集 $S(M_p(J))$ 中数据点的个数# $S(M_p(J))$ > 阈值T，则用 $S(M_p(J))$ 重新估计模型M，并输出结果；如果# $S(M_p(J))$ < 阈值T，返回到步骤2；
- 经过K次随机抽样，选择最大的一致集 $S(M_p(J))$，用 $S(M_p(J))$ 重新估计模型M，并输出结果。

示例问题

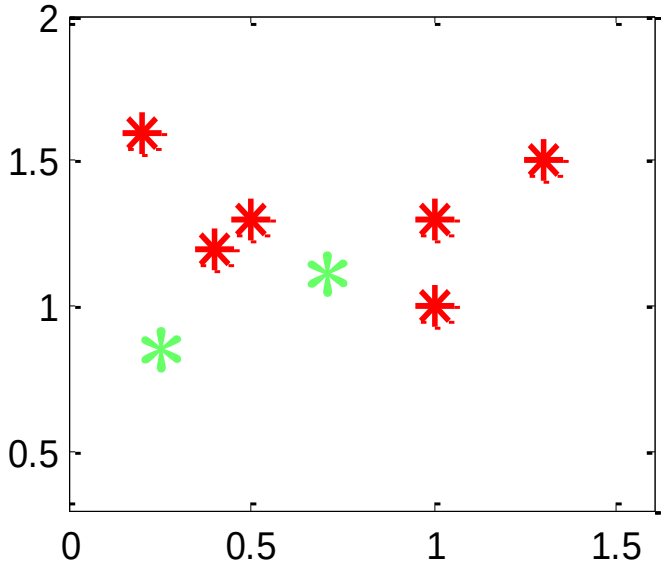

2
1.5
1
0.5
0
0.5
1
1.5

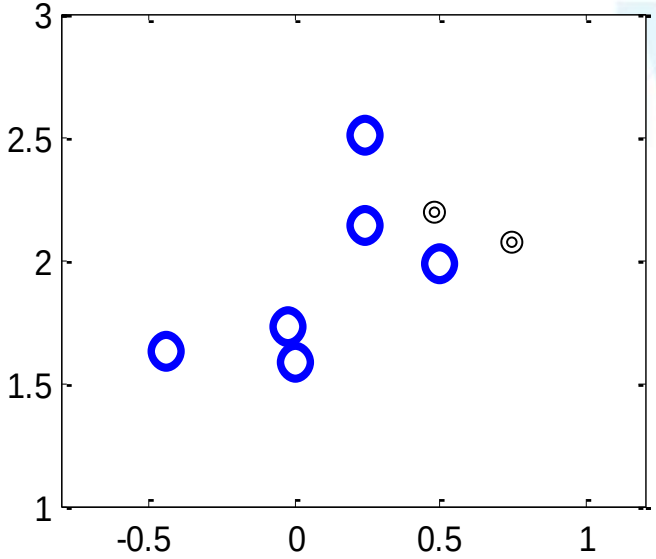

3
2.5
2
1.5
1
-0.5
0
0.5
1

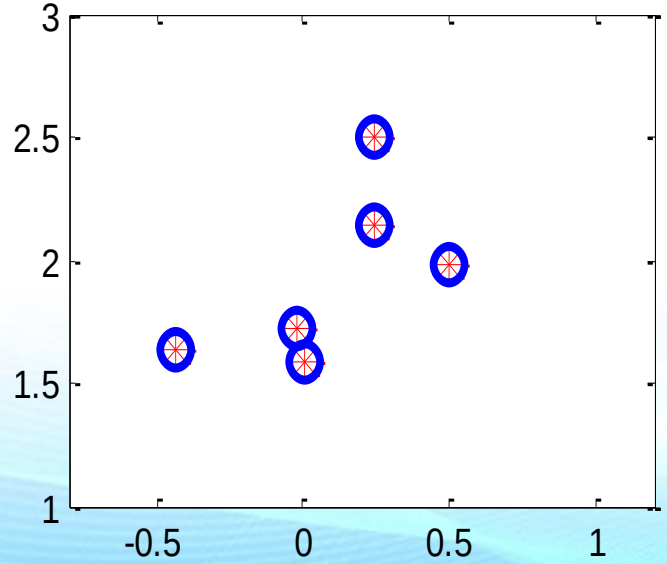

2.6
2.4
2.2
2
1.8
1.6
1.4
-0.5
0
0.5
1


3
2.5
2
1.5
1
-0.5
0
0.5
1

示例问题







小节

1、SIFT特征、ORB特征

2、特征描述子学习

3、ICP算法

4、RANSAC

练习

试编程实现SIFT算法，并在下图上进行匹配测试。



MAIS

谢谢！

